

**MEMINIMALKAN *OVER-PERSONALIZATION*
DALAM LINGKUNGAN PEMBELAJARAN
MELALUI INTEGRASI ASESMEN ADAPTIF DAN
MEKANISME KOLABORATIF**

Proposal Tugas Akhir

Oleh

**Dama Dhananjaya Daliman
18222047**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
November 2025**

LEMBAR PENGESAHAN

MEMINIMALKAN *OVER-PERSONALIZATION* DALAM LINGKUNGAN PEMBELAJARAN MELALUI INTEGRASI ASESMEN ADAPTIF DAN MEKANISME KOLABORATIF

Proposal Tugas Akhir

Oleh

Dama Dhananjaya Daliman
18222047

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 25 November 2025

Pembimbing

Ir. Windy Gambetta, MBA.
NIP. 196404301989031005

DAFTAR ISI

DAFTAR GAMBAR	iv
DAFTAR TABEL	v
DAFTAR KODE	vi
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	2
I.3 Tujuan	3
I.4 Batasan Masalah	3
I.5 Metodologi	4
II STUDI LITERATUR	5
II.1 Pembelajaran Adaptif dan Asesmen Adaptif	5
II.1.1 Jenis Penilaian	6
II.1.2 Luaran yang Dinilai	7
II.1.3 Taksonomi Bloom dalam Asesmen Kognitif	8
II.2 Pemodelan Siswa (<i>Student Modeling</i>)	9
II.3 Teknik dan Algoritma <i>Adaptive Assessment</i>	11
II.3.1 <i>Item Response Theory</i> (IRT)	11
II.3.2 <i>Factor Analysis</i> (FA)	13
II.3.3 <i>Hidden Markov Models</i> (HMM) dan <i>Bayesian Knowledge Tracing</i> (<i>BKT</i>)	13
II.3.4 <i>Deep Knowledge Tracing</i> (<i>DKT</i>)	14
II.3.5 Sistem <i>Elo-rating</i>	15
II.3.6 Posisi Teknik dan Algoritma dalam Sistem Asesmen Adaptif Individual	17
II.4 Pembelajaran Kolaboratif dan CSCL	19
II.4.1 Prinsip Pembelajaran Kolaboratif berbasis Teknologi	19
II.4.2 Pengukuran Heterogenitas Kelompok dan <i>Effect Size</i>	20
II.4.3 Aktivitas Pembelajaran Sosial dan Dampaknya	21
II.4.4 Tantangan dalam Menilai Kolaborasi	23
II.5 Upaya Integrasi Penilaian Personal dalam Lingkungan Kolaboratif yang Sudah Ada Saat Ini	24
II.6 Upaya Penyelesaian Masalah <i>Over-Personalization</i> yang Ada Saat Ini .	26

II.6.1	Sistem Rekomendasi yang Dapat Dikontrol Pengguna (<i>User-Controllable Recommender Systems</i>)	26
II.6.2	Pendekatan Berbasis Kelompok (<i>Group Recommender Systems</i>)	27
II.6.3	Pemodelan Komunitas Implisit untuk Memecahkan <i>Echo Chamber</i>	28
II.6.4	Mitigasi Dampak <i>Echo Chamber</i> Melalui <i>Constraint-Based Re-ranking</i>	29
II.6.5	Evaluasi Efektivitas Pembelajaran dengan <i>Normalized LearningGain</i>	32
III	ANALISIS MASALAH	34
III.1	Analisis Kondisi Saat Ini	34
III.2	Analisis Kebutuhan	35
III.2.1	Kebutuhan Fungsional	35
III.2.2	Kebutuhan Nonfungsional	36
III.2.3	Pemetaan Kebutuhan	37
III.3	Analisis Pemilihan Solusi	38
III.3.1	Alternatif Solusi	38
III.3.1.1	Alternatif Teknik Asesmen Kemahiran Individu (R1)	38
III.3.1.2	Alternatif Teknik Interaksi dan Asesmen Sosial (R2 & R3)	39
III.3.1.3	Alternatif Teknik Pencegahan <i>Echo Chamber</i> dan <i>Filter Bubble</i>	40
III.3.2	Analisis Penentuan Solusi	41
III.3.2.1	Keputusan 1: Penentuan Teknik Asesmen Individu	41
III.3.2.2	Keputusan 2: Penentuan Teknik Interaksi Sosial	42
III.3.2.3	Keputusan 3: Penentuan Teknik Mitigasi <i>Over-personalization</i>	43
III.3.3	Keputusan Akhir Pemilihan Solusi	45

DAFTAR GAMBAR

II.1	Contoh Model Konseptual dari BKT Standard yang Mengestimasi Transisi <i>State</i> siswa dari Belum Dipelajari (<i>Not Learned</i>) menjadi Sudah Dipelajari (<i>Learned</i>) (diadaptasi dari Minn (2022))	14
II.2	Model Konseptual Alur Proses Sistem Adaptif Individual (diadaptasi dari Vesin dkk. (2022))	18
II.3	Model Konseptual Antarmuka Pembelajaran Sosial (OSSM) (diadaptasi dari Brusilovsky dkk. (2016))	25
II.4	Model Konseptual Sistem Rekomendasi yang Dapat Dikontrol Pengguna (UCRS) (diadaptasi dari Wang dkk. (2022))	27
II.5	Diagram Arsitektur FRediECH (diadaptasi dari Tommasel, Rodriguez, dan Godoy (2021))	29

DAFTAR TABEL

III.1 Kebutuhan Fungsional (FR) Sistem	36
III.2 Kebutuhan Nonfungsional (NFR) Sistem	37
III.3 Pemetaan Masalah dan Kebutuhan Fungsional	37
III.4 Matriks Keputusan: Teknik Asesmen Individu	42
III.5 Matriks Keputusan: Teknik Interaksi Sosial	43
III.6 Matriks Keputusan: Teknik Mitigasi Isolasi	44

DAFTAR KODE

II.1	Algoritma Re-ranking	31
------	--------------------------------	----

BAB I

PENDAHULUAN

I.1 Latar Belakang

Pergeseran paradigma pendidikan tinggi global saat ini bergerak signifikan dari pendekatan pedagogis yang berpusat pada pengajar menuju pendekatan yang berpusat pada siswa (Ryoo dan Winkelmann 2021). Transformasi ini didorong oleh perkembangan *Personalized Learning* (PL), sebuah metode pendidikan yang menyesuaikan materi, urutan, dan kecepatan belajar berdasarkan keterampilan serta preferensi unik setiap individu. Kunci utama dalam merealisasikan personalisasi ini adalah pemanfaatan kecerdasan artifisial (AI) melalui sistem *Adaptive Assessment* (AA), yang mampu secara dinamis menyesuaikan tingkat kesulitan konten berdasarkan kinerja dan pengetahuan yang ditunjukkan oleh peserta didik secara *real-time* (Halkiopoulou dan Gkintoni 2024).

Menyadari potensi transformatif ini, pemerintah Indonesia telah menetapkan pendidikan dan riset sebagai salah satu dari lima bidang prioritas dalam Strategi Nasional Kecerdasan Artifisial (Stranas KA) 2020–2045 (Kelompok Kerja Penyusun Strategi Nasional untuk Kecerdasan Artifisial 2020). Dokumen strategis ini secara eksplisit menyerukan ditinggalkannya pendekatan kaku “*one size fits all*” dan mendorong eksplorasi pengembangan sistem penilaian cerdas yang adaptif. Secara teknis, berbagai algoritma telah dikembangkan untuk mendukung visi ini, mulai dari *Bayesian Knowledge Tracing* (BKT) yang memodelkan transisi penguasaan keterampilan, hingga *Deep Knowledge Tracing* (DKT) yang memanfaatkan *Recurrent Neural Network* (RNN) untuk pelacakan pengetahuan yang lebih presisi (Minn 2022). Metode yang lebih praktis dan dapat diinterpretasikan seperti sistem *Elo-rating* juga telah terbukti efisien secara komputasi untuk mengestimasi kemampuan siswa dan kesulitan soal secara dinamis (Vesin dkk. 2022).

Meskipun teknik-teknik tersebut unggul dalam mengoptimalkan jalur belajar indi-

vidu, penerapan yang naif terhadap algoritma yang hanya berfokus pada preferensi historis individu membawa risiko laten yang serius. Dalam literatur sistem rekomendasi modern, fenomena ini dikenal sebagai masalah *filter bubbles*, dalam fenomena ini algoritma secara tidak sengaja mengisolasi pengguna dari keragaman informasi dan perspektif dengan hanya menyajikan konten yang selaras dengan riwayat mereka (Wang dkk. 2022). Dalam konteks pendidikan, risiko ini bermanifestasi sebagai *over-personalization* (personalisasi berlebihan), yang menyebabkan sistem terlalu agresif dalam menyesuaikan konten dengan kenyamanan individu sehingga justru mengasingkan siswa dari manfaat pembelajaran komunitas (Halkiopoulou dan Gkintoni 2024). Algoritma yang bekerja semata-mata berdasarkan prinsip homofili (kemiripan) cenderung menciptakan *echo chambers* akademik (Tommasel, Rodriguez, dan Godoy 2021), menghalangi interaksi sosial yang krusial bagi pengembangan keterampilan kolaboratif.

Tinjauan literatur terkini mengonfirmasi adanya kesenjangan teknologi dalam mengatasi dilema ini. Mayoritas sistem asesmen adaptif yang ada saat ini masih berfokus eksklusif pada pelacakan pengetahuan individu tanpa mengintegrasikan mekanisme penilaian sosial (Ihichr dkk. 2024). Model-model yang berfokus tunggal seperti DKT atau sistem Elo standar secara inheren sulit menyeimbangkan antara memberikan materi yang paling sesuai kemampuan individu dengan materi yang memicu pertumbuhan melalui interaksi kelompok (Dokoupil 2022).

Kondisi ini menghadirkan tantangan sekaligus peluang strategis bagi implementasi Stranas KA di Indonesia. Jika pengembangan sistem pendidikan nasional hanya mengadopsi teknologi adaptif konvensional, Indonesia berisiko mewarisi kelemahan fundamental berupa isolasi pembelajaran tersebut. Oleh karena itu, pengembangan sistem asesmen di Indonesia tidak seharusnya sekadar meniru, melainkan perlu melakukan lompatan teknologi dengan merancang sistem yang sejak awal memitigasi risiko *over-personalization*. Dibutuhkan sebuah pendekatan baru yang mampu mengelola keseimbangan antara adaptivitas personal dan dinamika kolaboratif, memastikan bahwa intervensi teknologi memperkuat, bukan melemahkan, ekosistem pembelajaran sosial.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, teridentifikasi adanya kebutuhan mendesak untuk mengembangkan sistem asesmen yang selaras dengan Stranas KA, namun tahan terhadap risiko isolasi pembelajaran yang kerap muncul pada sistem adaptif kon-

vensional. Ketiadaan sistem yang mampu menyeimbangkan adaptivitas personal dengan interaksi sosial menjadi kesenjangan teknologi utama.

Maka dari itu, permasalahan utama yang ingin diselesaikan adalah:

1. Implementasi purwarupa sistem asesmen adaptif seperti apa yang mampu memitigasi efek *over-personalization* dengan mengintegrasikan metrik penilaian individual ke dalam mekanisme pembelajaran kolaboratif?
2. Bagaimana efektivitas purwarupa sistem tersebut dalam mempertahankan fungsionalitas adaptif (personalisasi) sekaligus memfasilitasi interaksi sosial yang relevan saat diujicobakan pada pengguna?

I.3 Tujuan

Tujuan utama dari tugas akhir ini adalah **membangun purwarupa sistem asesmen adaptif kolaboratif yang dirancang untuk meminimalisir risiko *over-personalization* dalam lingkungan pembelajaran daring.**

Secara spesifik, tujuan penelitian ini adalah:

1. Implementasi sistem terintegrasi antara algoritma asesmen adaptif dengan fitur kolaboratif, sehingga dapat merekomendasikan interaksi sosial yang relevan untuk mengatasi *over-personalization* dalam pembelajaran.
2. Mengevaluasi purwarupa sistem melalui uji coba pengguna untuk mengukur keberhasilan sistem dalam memberikan pengalaman belajar yang adaptif tanpa mengorbankan aspek kolaborasi.

I.4 Batasan Masalah

Untuk memastikan penelitian ini tetap fokus dan dapat diselesaikan dalam jangka waktu yang ditentukan, maka ditetapkan batasan-batasan sebagai berikut.

1. Batasan Konteks Strategis dan Kultural: Permasalahan asesmen adaptif yang dikaji akan difokuskan pada konteks yang selaras dengan visi Strategi Nasional Kecerdasan Artifisial (Stranas KA) Indonesia . Ini berarti penelitian berfokus pada pengembangan sistem yang mendukung ekosistem kolaboratif, yang disesuaikan dengan kebutuhan dan potensi implementasi di lingkungan pendidikan tinggi di Indonesia.
2. Fokus masalah utama penelitian ini adalah pada kesenjangan integrasi algoritmik antara asesmen adaptif individual dan asesmen kolaboratif. Penelitian tidak akan menginvestigasi masalah lain dalam asesmen adaptif (seperti de-

teksi gaya belajar atau deteksi kecurangan dalam asesmen), melainkan terbatas pada perancangan model yang menggabungkan metrik kemahiran personal dengan metrik kinerja sosial.

3. Permasalahan yang dikaji terbatas pada penilaian luaran kognitif (*cognitive outcomes*), yaitu pelacakan ”keterampilan” dan ”pengetahuan” siswa. Penelitian ini tidak akan mencakup perancangan model untuk menilai luaran afektif (seperti motivasi atau kepuasan) atau luaran perilaku (seperti durasi belajar) sebagai ukuran utama kemahiran.

I.5 Metodologi

Pelaksanaan tugas akhir ini akan mengadopsi dan mengadaptasi metodologi yang digunakan oleh Vesin dkk. (2022) dalam penelitian mereka mengenai asesmen adaptif dan rekomendasi konten. Metodologi ini terdiri atas beberapa tahapan utama yang sistematis, dimulai dari studi pendahuluan hingga analisis data sebagai .

1. **Studi Literatur:** Melakukan tinjauan sistematis terhadap penelitian terkait asesmen adaptif, pembelajaran kolaboratif, dan implementasi sistem serupa.
2. **Perancangan dan Pengembangan Sistem:** Merancang arsitektur perangkat lunak serta mengimplementasikan modul-modul sistem, termasuk integrasi algoritma asesmen adaptif dan antarmuka pengguna kolaboratif.
3. **Sesi Pengguna (Pengujian dan Evaluasi):** Melaksanakan studi dengan partisipan sebagai sampel populasi pengguna untuk mengumpulkan data kuantitatif dan kualitatif mengenai penggunaan dan pengalaman mereka terhadap purwarupa sistem. Data yang dikumpulkan dapat mencakup data interaksi (*click-streams*, *log files*), hasil asesmen (peringkat yang dihasilkan), serta umpan balik pengguna (misalnya melalui survei atau wawancara).
4. **Analisis Data:** Menganalisis data yang terkumpul untuk mengevaluasi fungsionalitas purwarupa dan efektivitas sistem dalam konteks asesmen adaptif dan kolaboratif, guna menjawab rumusan masalah serta tujuan penelitian.
5. **Penarikan Kesimpulan dan Pelaporan:** Menyusun laporan tugas akhir berdasarkan hasil analisis dan temuan penelitian.

BAB II

STUDI LITERATUR

II.1 Pembelajaran Adaptif dan Asesmen Adaptif

Lingkungan pembelajaran adaptif (*adaptive learning environments*) bertujuan untuk meningkatkan perolehan pembelajaran individu dan pengalaman siswa dalam lingkungan pembelajaran yang dipersonalisasi. Untuk mendukung pengembangan lingkungan pembelajaran adaptif secara efektif, diperlukan metode asesmen pengetahuan yang efisien untuk menilai keterampilan siswa secara empiris (Minn 2022). Penilaian pembelajar adalah salah satu momen utama dalam proses pendidikan.

Pembelajaran adaptif (*adaptive learning*), secara definisi, adalah metodologi untuk menyesuaikan dan mempersonalisasi proses pembelajaran, terutama konten, kepada seorang pembelajar, agar sesuai dengan situasi dan keadaan yang berbeda. Tujuan dari *adaptive learning system* (ALS) atau sistem pembelajaran adaptif (ALS) adalah untuk mengubah instruksi menggunakan seperangkat aturan yang telah ditentukan untuk menyediakan materi pembelajaran yang disesuaikan dengan kebutuhan dan perilaku siswa. Pembelajaran adaptif memberikan kemungkinan untuk menjadikan pembelajar sebagai kolaborator dalam proses pendidikan alih-alih penerima informasi pasif, karena setiap pembelajar memiliki jalur pembelajaran optimal spesifik yang terdiri dari banyak titik terhubung, dan setiap titik mewakili komponen pengetahuan atau keterampilan (Ihichr dkk. 2024).

Pembelajaran adaptif mempertimbangkan banyak aspek, seperti tingkat pembelajar saat ini, kebutuhan individu, gaya belajar, dan interaksi yang berbeda dengan siswa untuk mengindividualisasi semua komponen proses pembelajaran: konten, antarmuka, gaya belajar, dan asesmen. Oleh karena itu, pembelajaran adaptif memungkinkan seorang siswa untuk maju ke materi yang lebih menantang berdasarkan kinerjanya, sambil di sisi lain tetap memberikan dukungan tambahan kepada siswa lainnya untuk menguasai keterampilan tertentu. Pendekatan ini memastikan bah-

wa pembelajar tidak dibatasi oleh kecepatan kelas tetapi dapat mengikuti kecepatan belajar mereka sendiri. Dengan demikian, instruktur dan pembelajar dapat membuat keputusan yang tepat pada saat yang tepat dengan mengikuti kurva belajar dan lintasan belajar (*learning path*). Singkatnya, pembelajaran adaptif berusaha untuk menyesuaikan pengalaman pendidikan untuk membantu siswa mencapai tujuan pembelajaran mereka dengan meniru interaksi personalisasi satu lawan satu antara seorang guru dan seorang pembelajar (Ihichr dkk. 2024).

Pernyataan oleh psikolog Lauren Resnick, "Apa yang kita nilai adalah apa yang kita hargai. Kita mendapatkan apa yang kita nilai, dan jika kita tidak menilainya, kita tidak mendapatkannya", menunjukkan pentingnya asesmen sebagai langkah utama dan kritis dalam proses pendidikan. Banyak sistem pembelajaran adaptif lebih fokus pada asesmen daripada konten. Data asesmen yang dikumpulkan dari respons siswa digunakan untuk mempersonalisasi proses pembelajaran, menciptakan jalur yang disesuaikan berdasarkan hasil. Jalur ini terus diperbarui dengan setiap asesmen. Dengan demikian, asesmen pembelajar dianggap sebagai faktor krusial untuk proses *e-learning* yang sukses (Ihichr dkk. 2024).

Berbeda dengan pengujian konvensional, yang didasarkan pada *item* tetap yang harus dihadapi setiap peserta ujian terlepas dari tingkat pengetahuan mereka, asesmen adaptif memungkinkan pemilihan pertanyaan berdasarkan kinerja peserta ujian. Sistem asesmen adaptif secara terus-menerus menyesuaikan kembali proses asesmennya sehubungan dengan tingkat kesulitan, dan sesuai dengan kinerja, preferensi, motivasi, pengetahuan, serta tujuan pendidikan yang diekspresikan oleh pembelajar (Halkiopoulou dan Gkintoni 2024). Asesmen adaptif menyediakan tes singkat yang dipersonalisasi, *item*-nya berubah tergantung pada respons siswa, dan kesulitan setiap pertanyaan berkorelasi dengan jawaban pertanyaan sebelumnya. Singkatnya, asesmen adaptif berusaha menghindari penyajian pertanyaan mudah kepada siswa yang mampu, yang kemungkinan akan menjawab dengan benar, dan pertanyaan menantang tidak disajikan kepada siswa yang kesulitan (Ihichr dkk. 2024).

II.1.1 Jenis Penilaian

Menurut Ihichr dkk. (2024), asesmen pengetahuan secara global dapat dibagi menjadi tiga jenis: sumatif, formatif, dan pra-asesmen. Umumnya, asesmen sumatif lebih dominan daripada asesmen formatif dalam *e-learning*, tetapi dua jenis terakhir telah menunjukkan potensi lebih, terutama dalam pembelajaran adaptif.

1. Asesmen sumatif juga dikenal sebagai asesmen pembelajaran (*assessment of learning*), jenis evaluasi ini terjadi di akhir siklus pembelajaran untuk meng-

ukur pencapaian pembelajar dan memverifikasi penguasaan unit kurikulum. Asesmen ini bertujuan menilai kemajuan kumulatif pembelajar (Ihichr dkk. 2024). Informasi dari asesmen sumatif dapat digunakan secara formatif untuk memandu aktivitas mereka di pembelajaran selanjutnya (Minn 2022).

2. Asesmen formatif atau yang disebut juga asesmen untuk pembelajaran (*assessment for learning*), ini terjadi sepanjang siklus pembelajaran untuk memberikan informasi umpan balik kepada tutor dan pembelajar untuk membantu meningkatkan pengalaman belajar mereka. Jenis asesmen ini menilai kualitas pembelajaran dengan memposisikan asesmen antara pengajaran dan pembelajaran (kemajuan saat ini) alih-alih diposisikan hanya di akhir proses. Ketika asesmen formatif begitu tertanam dalam lingkungan pembelajaran sehingga pemisahan antara asesmen dan pembelajaran benar-benar kabur dan tidak terlihat oleh siswa, konsep ini dikenal sebagai *stealth assessment*. Asesmen formatif memungkinkan kita untuk menyempurnakan lintasan pembelajaran, meningkatkan keterlibatan dan antusiasme siswa untuk menguasai suatu materi pembelajaran dan mengembangkan disiplin dalam dirinya (Ihichr dkk. 2024).
3. Pra-asesmen atau yang dikenal sebagai asesmen diagnostik, jenis asesmen ini mengukur kompetensi awal setiap pembelajar, memberikan gambaran yang jelas kepada guru tentang tingkat keterampilan pembelajar. Ini seringkali diikuti oleh semacam instruksi kompensasi untuk menghilangkan hambatan dan menawarkan berbagai jenis kegiatan remedial. Pra-asesmen biasanya dilakukan di awal pembelajaran dan dirancang untuk mengukur pengetahuan yang sudah diperoleh sebelumnya oleh siswa untuk mengidentifikasi kebutuhan, kompetensi, prasangka, dan pengetahuan sebelumnya dari siswa tersebut, untuk mengarahkan mereka ke kurikulum yang paling sesuai (Ihichr dkk. 2024).

II.1.2 Luaran yang Dinilai

Ihichr dkk. (2024) mendefinisikan tiga hasil pembelajaran utama yang dinilai dalam pembelajaran daring, yaitu hasil pembelajaran kognitif, perilaku, dan afektif. Studi tersebut menunjukkan bahwa ketiga aspek ini saling berkorelasi.

1. **Luaran Kognitif:** luaran ini secara mendasar berkaitan dengan pengetahuan yang diperoleh dan keterampilan intelektual. Pengetahuan adalah semua informasi yang telah dipelajari siswa dari suatu topik, tetapi keterampilan intelektual menyangkut kemampuan yang berbeda, seperti penalaran, proses berpikir, dan pengambilan keputusan (Ihichr dkk. 2024).

2. **Luaran Perilaku:** luaran perilaku merujuk pada pengukuran keterlibatan pembelajar dengan memantau perilakunya selama pembelajaran seperti durasi dan waktu belajar, partisipasi dalam forum dan diskusi, pengumpulan tugas, dan penyelesaian tes (Ihichr dkk. 2024).
3. **Luaran Afektif:** luaran ketiga ini berkaitan dengan persepsi siswa, kepuasan mereka terhadap pembelajaran, apresiasi terhadap pengalaman belajar mereka, dan manfaat yang diharapkan oleh mereka ketika mendaftarkan diri mengikuti suatu pembelajaran. Sebagian besar pembelajaran dan asesmen di pendidikan tinggi berkonsentrasi pada hasil kognitif daripada hasil afektif dan perilaku (Ihichr dkk. 2024).

II.1.3 Taksonomi Bloom dalam Asesmen Kognitif

Kerangka kerja fundamental yang digunakan untuk mengklasifikasikan tujuan pendidikan dan mengukur kedalaman kognitif siswa adalah *Bloom's Revised Taxonomy*. Sebagaimana dijelaskan oleh Gosselin dan Okamoto (2018), taksonomi ini membagi domain kognitif menjadi enam tingkatan hierarkis, yang bergerak dari proses berpikir tingkat rendah (*lower-order cognition*) menuju tingkat tinggi (*high-level cognition*). Tingkatan tersebut dimulai dari *Remembering* (mengingat) dan *Understanding* (memahami) sebagai fondasi dasar, kemudian berlanjut ke *Applying* (menerapkan), *Analyzing* (menganalisis), *Evaluating* (mengevaluasi), hingga puncaknya pada *Creating* (mencipta). Dalam konteks asesmen, idealnya *Performance Indicators* (PI) dirancang dengan memadukan berbagai level ini, sehingga siswa tidak hanya dituntut untuk mengingat fakta, tetapi juga menerapkan materi yang dipelajari dalam cara-cara yang kompleks. Penggunaan taksonomi ini memungkinkan penerjemahan luaran pembelajaran yang abstrak menjadi perilaku yang dapat diamati (*observable behaviors*) dan diukur secara konkret.

Penerapan taksonomi ini dalam sistem asesmen memerlukan instrumen yang presisi, seperti penggunaan *descriptive rubrics* (rubrik deskriptif). Gosselin dan Okamoto (2018) menekankan bahwa penggunaan rubrik deskriptif yang diselaraskan dengan kata kerja operasional Bloom dapat meningkatkan konsistensi penilaian antar-evaluator dan memberikan umpan balik yang lebih bermakna dibandingkan sekadar skala numerik generik. Rubrik ini mendeskripsikan variasi tingkat kinerja untuk setiap kriteria secara spesifik. Misalnya, dalam menilai kemampuan desain teknik, indikator kinerja direvisi dari sekadar berbasis topik menjadi berbasis level kognitif, seperti bergerak dari kemampuan "mengidentifikasi prinsip sains" (*Understanding*) menuju kemampuan "membuat asumsi penyederhanaan dan mengevaluasi solusi" (*Evalua-*

ting). Pendekatan ini sangat relevan untuk asesmen sejawat (*peer assessment*) karena rubrik yang terstruktur digunakan dalam asesmen untuk membantu siswa menilai kontribusi rekannya secara objektif berdasarkan deskripsi kinerja yang jelas, bukan sekadar persepsi subjektif.

Dalam disiplin ilmu komputasi, penggunaan kata kerja standar Bloom sering kali tidak memadai untuk menangkap nuansa teknis dari tugas-tugas pemrograman dan sistem informasi. Untuk mengatasi keterbatasan ini, Computing Education in Community Colleges (2023) melalui *ACM Committee for Computing Education in Community Colleges* (CCECC) mengusulkan peningkatan taksonomi dengan menambahkan 56 kata kerja spesifik komputasi (*enhanced verbs*). Modifikasi ini memetakan aktivitas teknis ke dalam level kognitif yang sesuai. Sebagai contoh, aktivitas *Code* (mengodekan), *Build* (membangun), dan *Decrypt* (mendekripsi) dikategorikan ke dalam level *Applying*. Sementara itu, aktivitas yang membutuhkan pemecahan masalah lebih dalam seperti *Debug* (men-debug), *Optimize* (mengoptimalkan), dan *Refactor* diposisikan pada level *Evaluating*. Aktivitas sintesis seperti *Script* (membuat skrip), *Virtualize* (memvirtualisasi), dan *Program* (membuat program solusi) ditempatkan pada level tertinggi, yaitu *Creating*.

Integrasi kata kerja komputasi ini memungkinkan perancangan *competencies* yang lebih akurat, yang didefinisikan sebagai integrasi antara pengetahuan (*knowledge*), keterampilan (*skills*), dan disposisi (*dispositions*) dalam konteks tertentu (Computing Education in Community Colleges 2023). Dalam lingkungan pembelajaran adaptif, pemetaan ini krusial untuk melacak progresi siswa. Seorang siswa mungkin memulai pembelajaran pada level *Applying* dengan menerjemahkan spesifikasi menjadi kode, namun seiring waktu diharapkan berkembang ke level *Creating* dengan mengimplementasikan solusi untuk masalah abstrak. Computing Education in Community Colleges (2023) juga menyoroti bahwa disposisi atau aspek "sikap" (seperti *collaborative* dan *meticulous*) dapat dikaitkan dengan kompetensi teknis tersebut. Dengan demikian, sistem asesmen tidak hanya melacak kebenaran sintaksis kode, tetapi juga kedalaman pemahaman konseptual dan kemampuan kolaboratif siswa berdasarkan hierarki kognitif yang terstandarisasi.

II.2 Pemodelan Siswa (*Student Modeling*)

Dalam konteks lingkungan pembelajaran adaptif, asesmen pengetahuan diperlukan untuk membangun sebuah *student model* (model siswa). Model siswa adalah inti dari setiap sistem pendidikan adaptif, yang juga dikenal sebagai *learner model*

(Brusilovsky dkk. 2016). Model ini berfungsi sebagai blok pembangunan fundamental (*fundamental building block*) dari asesmen pengetahuan (Minn 2022). Tujuan utamanya adalah untuk merepresentasikan keadaan pengetahuan domain (*domain knowledge*) siswa saat ini. Selain pengetahuan, *student model* juga dapat merepresentasikan informasi lain tentang siswa seperti tujuan pembelajaran (*learning goals*), sifat-sifat personal (*personal traits*), dan/atau preferensi. Dengan menggunakan *student model* inilah sebuah sistem adaptif dapat menyediakan berbagai intervensi pembelajaran yang dipersonalisasi, seperti *mastery learning* atau *adaptive sequencing* (pengurutan adaptif) (Brusilovsky dkk. 2016).

Untuk membangun *student model* secara efektif, diperlukan sebuah *domain model* (model domain) sebagai landasan (Minn 2022). *Domain model* ini berfungsi untuk mengekstrak apa yang disebut sebagai **Knowledge Components** (KCs) atau keterampilan (*skills*) dan atribut laten (*latent attributes*) yang mendasari setiap tugas atau materi pembelajaran. *Knowledge Components* ini adalah faktor laten (*latent factors*) yang tidak pernah dapat diamati secara langsung, namun keberadaannya dianggap menentukan hasil atau kinerja siswa pada suatu tugas. Dalam kerangka kerja psikometri, pemetaan antara *item* (pertanyaan) dan KCs yang diperlukannya seringkali direpresentasikan dalam sebuah **Q-matrix** (Minn 2022). Oleh karena itu, berbagai teknik asesmen adaptif (yang akan dibahas berikutnya) pada dasarnya adalah algoritma yang digunakan untuk memperkirakan penguasaan siswa atas KCs yang tersembunyi ini.

Dalam sebagian besar sistem pembelajaran terpersonalisasi, *student model* bersifat tersembunyi atau tidak dapat diamati (*unobservable*) oleh siswa, dan hanya digunakan oleh sistem untuk menggerakkan adaptasi. Namun, sebuah pendekatan yang dikenal sebagai **Open Student Modeling** (OSM) atau Pemodelan Siswa Terbuka, berusaha membuat terobosan baru dengan secara sengaja memperlihatkan aspek-aspek model tersebut kepada pembelajar. Tujuan dari pendekatan OSM adalah untuk meningkatkan *self-reflection* (refleksi diri) siswa, *self-regulated learning* (pembelajaran mandiri), transparansi personalisasi, dan motivasi siswa (Brusilovsky dkk. 2016; Ihichr dkk. 2024).

Sebuah ekstensi yang lebih baru dan relevan dengan penelitian ini adalah **Open Social Student Modeling** (OSSM) atau Pemodelan Siswa Sosial Terbuka. Ide dari OSSM adalah untuk melengkapi aspek kognitif OSM dengan aspek sosial. Hal ini dicapai dengan mengizinkan siswa untuk mengeksplorasi model-model rekan siswa dan/atau model kelas yang diagregasi. Pendekatan ini memiliki kesamaan dengan

teknik *gamification* seperti *leaderboards* (papan peringkat), yang bertujuan memanfaatkan perbandingan sosial untuk meningkatkan motivasi dan keterlibatan siswa. Penelitian telah menunjukkan bahwa antarmuka OSSM, seperti yang diimplementasikan dalam *MasteryGrids*, dapat ”meningkatkan pembelajaran, terutama untuk siswa dengan pengetahuan awal yang lebih rendah” (Brusilovsky dkk. 2016).

II.3 Teknik dan Algoritma *Adaptive Assessment*

Dalam rangka mencapai adaptivitas, sistem pembelajaran perlu memperkirakan tingkat kompetensi siswa dan tingkat kesulitan konten pendidikan (Vesin dkk. 2022). Berbagai teknik dan algoritma telah dikembangkan untuk memungkinkan asesmen adaptif, masing-masing dengan dasar teoretis dan karakteristiknya sendiri. Bagian ini mengulas beberapa pendekatan utama yang digunakan dalam asesmen adaptif, dengan fokus pada *Item Response Theory* (IRT), IRT* atau *Bayesian IRT*, *Hidden Markov Models* (HMM), *Factor Analysis* (FA), *Bayesian Knowledge Tracing* (BKT), *Deep Knowledge Tracing* (DKT), dan sistem *Elo-rating*.

II.3.1 *Item Response Theory* (IRT)

Item Response Theory (IRT) adalah salah satu teori yang paling banyak digunakan dalam asesmen adaptif, dengan asal-usulnya berasal dari Rasch dan Lord pada tahun 1950-an. Teori psikometri ini digunakan untuk memperkirakan pengetahuan pembelajar, mengembangkan pengukuran kognitif atau non-kognitif pembelajar, memilih pertanyaan berikutnya yang sesuai pada setiap momen, dan memutuskan kapan tes selesai (Ihichr dkk. 2024). Dalam IRT, probabilitas keberhasilan pada suatu tugas (*item*) dipetakan sebagai fungsi dari tingkat kemahiran (*ability*) yang mempertimbangkan keseluruhan tugas, dengan asumsi bahwa keadaan pengetahuan siswa statis selama ujian. Keadaan pengetahuan siswa θ dinilai berdasarkan kemahirannya saat tes dilakukan, dan setiap *item* yang diuji membantu memberikan informasi untuk menyempurnakan estimasi keadaan pengetahuan θ_i . Model IRT dasar mengasumsikan satu keterampilan tunggal dan bahwa *item* tes bersifat unidimensional (Minn 2022). Secara formal, model IRT dasar bisa diekspresikan dengan rumus matematika seperti berikut ini.

$$\begin{aligned} P_{ij} &= \sigma(\theta_i - \beta_j) \\ &= \frac{1}{1 + e^{\theta_i - \beta_j}} \end{aligned} \quad (\text{II.1})$$

Model IRT bisa dirancang dengan berbagai variasi parameter logistik. Model IRT dengan 1-Parameter Logistik (1PL) hanya melibatkan satu karakteristik *item*, yaitu kesulitan *item* (b), sedangkan model 2PL melibatkan kesulitan *item* (b) dan diskriminasi *item* (a), dan model 3PL menambahkan karakteristik ketiga, yaitu tebakan (*lower asymptote*) *item* (c) (Handayani dkk. 2025). IRT bukanlah pendekatan *Knowledge Tracing* karena mengasumsikan siswa tidak belajar selama proses pengujian; ini dianggap sebagai pendekatan *Knowledge Assessment* (Minn 2022). Namun, IRT memiliki tantangan dalam hal kalibrasi pada sampel besar dan kesulitan komputasi untuk pembaruan yang sering karena estimasi keterampilan baru harus dihitung untuk setiap siswa setelah satu respons untuk satu tugas (Vesin dkk. 2022).

Selain pendekatan standar, model IRT juga dapat diterapkan dalam kerangka kerja Bayesian (*Bayesian framework*), pendekatan ini dalam Minn (2022) disebut sebagai IRT*. Pendekatan Bayesian untuk IRT memungkinkan peneliti untuk memasukkan informasi sebelumnya (*prior information*) tentang parameter model. *Prior* ini dapat ditentukan dengan berbagai cara, seperti menggunakan estimasi parameter dari studi sebelumnya atau menggunakan *prior* yang tidak informatif jika tidak ada informasi yang tersedia. Sebagai contoh, dalam kerangka kerja ini, tingkat kesulitan sebuah *item* dapat diperkirakan dari *item* lain yang serupa, atau kemampuan siswa dapat diperkirakan dari kinerjanya (*performance*) pada tugas-tugas lain. Pendekatan ini memanfaatkan pendekatan Bayesian dan melakukan regularisasi terhadap $\log P_{ij}$ dengan menerapkan distribusi standard *normal prior* independen ke setiap θ_i dan β_j . Dengan demikian, model ini memaksimalkan probabilitas log posterior dari θ_i, β_j jika diketahui data respons $r: (i, j, r, t) \in D$, dengan r adalah respons biner (nilainya antara 0 dan 1), t adalah waktu ketika respons diberikan, dan D adalah kumpulan *tuple* (i, j, r, t) yang menunjukkan semua respons yang diberikan oleh siswa i pada *item* j pada waktu t . Dalam penelitian oleh Minn (2022), model IRT* dapat dirumuskan sebagai berikut.

$$\begin{aligned} \log P(\{\theta_i\}, \{\beta_j\} | D) = & \sum_{(i,j,r,t) \in D} r \log \sigma(\theta_i - \beta_j) + (1 - r) \\ & \log(1 - \sigma(\theta_i - \beta_j)) - \frac{1}{2} \sum_i \theta_i^2 - \frac{1}{2} \sum_j \beta_j^2 + C \quad (\text{II.2}) \end{aligned}$$

II.3.2 *Factor Analysis (FA)*

Factor Analysis (FA) atau Analisis Faktor adalah teknik psikometri yang menjelaskan korelasi antar variabel yang teramati (*observed variables*). Dalam konteks asesmen adaptif, FA utamanya berfungsi untuk membangun model pembelajar, khususnya komponen kognitif, dengan mengeksplorasi faktor-faktor yang memengaruhi proses pembelajaran. Faktor-faktor ini mungkin termasuk pengetahuan sebelumnya (*prior knowledge*), kemampuan kognitif, dan motivasi. FA membantu dalam menentukan *item* yang paling baik mengukur kemahiran pembelajar dan dalam menghasilkan umpan balik adaptif (Ihichr dkk. 2024).

Model berbasis FA memperkirakan kemahiran siswa pada setiap atribut (keterampilan) sebagai variabel laten kontinu. Model FA dapat dibagi menjadi dua kategori: *exploratory factor analysis* (EFA) dan *confirmatory factor analysis* (CFA). EFA digunakan untuk mengidentifikasi struktur faktor yang mendasari (*underlying factor structure*) dan mengurangi jumlah total *item* tes. CFA, di sisi lain, digunakan untuk memverifikasi apakah struktur faktor yang dihipotesiskan konsisten dengan data respons siswa. Dalam CFA, peneliti perlu menentukan terlebih dahulu jumlah faktor laten dan *item* mana yang terkait dengan faktor mana sebelum melakukan analisis (Minn 2022).


II.3.3 *Hidden Markov Models (HMM) dan Bayesian Knowledge Tracing (BKT)*

Hidden Markov Model (HMM) adalah model statistik yang mengasumsikan bahwa sistem yang dimodelkan adalah proses Markov dengan keadaan yang tidak teramati (*hidden states*). Dalam konteks asesmen pengetahuan, keadaan tersembunyi adalah penguasaan siswa terhadap suatu keterampilan. HMM memiliki dua asumsi utama. Asumsi pertama adalah bahwa keadaan pada waktu t hanya bergantung pada keadaan pada waktu $t - 1$. Asumsi kedua adalah bahwa observasi (misalnya, jawaban siswa) pada waktu t hanya bergantung pada keadaan pada waktu t . Dalam model ini, keadaan pengetahuan siswa dimodelkan sebagai variabel laten yang bertransisi antar keadaan (misalnya, dari "belum dipelajari" ke "dipelajari"), dan probabilitas transisi ini diperbarui berdasarkan urutan kinerja siswa yang teramati (Minn 2022).

Salah satu penerapan HMM yang paling luas dalam asesmen adaptif adalah *Bayesian Knowledge Tracing (BKT)*, suatu pendekatan yang didasarkan pada *Bayesian Networks* (BNs). Pendekatan ini mencoba memodelkan keterampilan pembelajar dengan menghitung probabilitas penguasaan keterampilan berdasarkan seperangkat parameter: menebak (*guessing*), terpeleset (*slipping*), probabilitas bahwa keteram-

pilan sudah dikuasai sebelumnya, dan probabilitas bahwa keterampilan akan dipelajari. BKT memperhitungkan urutan waktu untuk memperkirakan keterampilan baru dan mengasumsikan bahwa setiap keterampilan yang dipelajari tidak pernah dilupakan (Ihichr dkk. 2024).

BKT adalah pendekatan paling awal untuk memodelkan keadaan pengetahuan pembelajar yang berubah dan merupakan model pertama yang melonggarkan asumsi keadaan pengetahuan statis. Dalam BKT standar, satu keterampilan tunggal diuji per *item* dan keadaan penguasaan keterampilan pembelajar disimpulkan pada setiap langkah waktu berdasarkan urutan hasil sebelumnya. BKT mengandalkan model Markov untuk menyimpulkan keadaan penguasaan, dari "belum dipelajari" menjadi "dipelajari". Berbagai ekstensi BKT telah diperkenalkan, seperti memperhitungkan pengetahuan sebelumnya siswa atau kesulitan *item* (Minn 2022).



Gambar II.1 Contoh Model Konseptual dari BKT Standard yang Mengestimasi Transisi *State* siswa dari Belum Dipelajari (*Not Learned*) menjadi Sudah Dipelajari (*Learned*) (diadaptasi dari Minn (2022))

II.3.4 *Deep Knowledge Tracing (DKT)*

Deep Knowledge Tracing (DKT), sebuah algoritma perintis yang menggunakan jaringan neural rekuren dalam (*deep recurrent neural networks*) untuk memodelkan pembelajaran siswa dan melacak pengetahuan mereka, digunakan untuk mengeks-

trak struktur laten antar asesmen. DKT bergantung pada model RNN dan LSTM, yang menawarkan keuntungan signifikan dengan menangkap representasi pengetahuan yang kompleks dari asesmen dari waktu ke waktu. Kemampuan ini memungkinkan kinerja prediksi yang jauh lebih baik di seluruh dataset dari asesmen sebelumnya. Selain itu, model yang dipelajari dapat digunakan untuk merancang asesmen berikutnya yang lebih sesuai untuk siswa (Ihichr dkk. 2024).

DKT menggunakan data yang diperoleh dari pengujian keterampilan dan hasil pengujiannya digunakan untuk memprediksi upaya urutan pembelajaran di masa mendatang. DKT menggunakan sejumlah besar neuron buatan untuk mewakili keadaan pengetahuan laten bersama dengan struktur dinamis temporal yang memungkinkan model untuk mempelajari keadaan pengetahuan siswa dari data. Namun, seperti model *deep learning* lainnya, DKT seringkali berfungsi sebagai *black box* dengan sejumlah besar parameter dan struktur yang kompleks, sehingga sulit untuk memberikan penjelasan yang bermakna secara psikologis yang mencerminkan teori evolusi kognitif manusia (Minn 2022).

II.3.5 Sistem *Elo-rating*

Sistem *Elo-rating*, yang awalnya dikembangkan untuk memberi peringkat pemain catur, baru-baru ini digunakan dalam pendidikan untuk mengatasi beberapa celah yang ditimbulkan oleh model IRT. *Elo-rating* sepenuhnya bergantung pada evaluasi kuantitatif kinerja siswa, dan dapat memodelkan keterampilan yang berubah seiring waktu. Ketika *item* baru ditambahkan dalam sistem, tidak perlu menetapkan kesulitan *item* awal yang benar, karena sistem akan belajar dan menetapkan tingkat kesulitan untuk konten pendidikan, berdasarkan kebenaran jawaban siswa. Terakhir, algoritma *Elo-rating* dapat memberikan estimasi kesulitan tugas yang akurat dengan ukuran sampel kecil, sesuatu yang tidak mungkin dilakukan dengan model IRT (Vesin dkk. 2022). Adaptasi *Elo-rating* ke bidang pendidikan mengasumsikan bahwa siswa adalah pemain dan *item* konten (misalnya, latihan penulisan kode program) adalah lawan.

Peringkat *Elo* siswa dan konten diwakili oleh angka, yang meningkat atau menurun tergantung pada tindakan siswa dengan sumber belajar. Perbedaan peringkat antara siswa dan *item* berfungsi sebagai prediktor hasil tindakan. Algoritma *Elo-rating* merupakan algoritma yang hemat sumber daya komputasi, sangat sederhana untuk diimplementasikan, dan cocok untuk praktik adaptif dalam pendidikan (Vesin dkk. 2022). Implementasi yang diusulkan oleh Vesin dkk. (2022) memperluas *Elo-rating* klasik dengan mempertimbangkan parameter tambahan seperti jumlah upaya

dan waktu yang digunakan, bukan hanya status terselesaikan atau tidak, untuk memberikan adaptivitas dan rekomendasi dalam tugas pemrograman *open-ended*.

Secara spesifik, metode yang diusulkan menerapkan dua strategi, (1) memperbarui peringkat berdasarkan performa siswa pada materi pembelajaran dibandingkan nilai ekspektasinya dan (2) tingkat kesulitan konten pembelajaran diperbarui berdasarkan tingkat pemahaman siswa yang berhasil, ataupun gagal dalam latihan. Secara matematis, cara ini mengestimasi probabilitas seorang siswa i mampu menyelesaikan latihan j berdasarkan peringkat siswa saat ini dan tingkat kesulitan latihan j . Peringkat siswa dan kesulitan latihan kemudian diperbarui menurut rumus berikut.

$$R_i = R_{i-1} + K(W - W_e) \quad (\text{II.3})$$

$$D_j = D_{j-1} + K(W_e - W) \quad (\text{II.4})$$

dengan R_i adalah peringkat siswa setelah menyelesaikan latihan ke- i , R_{i-1} adalah peringkat siswa sebelum menyelesaikan latihan ke- i , D_j adalah tingkat kesulitan latihan ke- j setelah siswa menyelesaikannya, D_{j-1} adalah tingkat kesulitan latihan ke- j sebelum siswa menyelesaikannya, K adalah faktor penyesuaian yang menentukan seberapa besar perubahan peringkat atau tingkat kesulitan, nilai ini dikurangi secara bertahap seiring siswa menyelesaikan lebih banyak latihan, W merepresentasikan hasil dari penyelesaian latihan yang direkomendasikan (dengan kata lain adalah tingkat keberhasilan), yang dihitung berdasarkan formula berikut.

$$W = \left(\frac{(A_s + A_o)T_c}{2A_oT_p} \right) (a_id_i - a_it_i). \quad (\text{II.5})$$

Rumus II.5 di atas adalah kunci modifikasi algoritma *elo-rating* dari riset oleh Vesin dkk. (2022), variabel-variabelnya dijelaskan dalam laporan hasil risetnya dengan definisi di bawah ini:

- A_s : banyaknya upaya yang berhasil untuk latihan tertentu
- A_o : banyaknya total upaya untuk latihan tertentu
- T_c : banyaknya latihan yang sudah diselesaikan
- T_p : banyaknya latihan yang diselesaikan dengan benar


- a_i : bobot yang menentukan seberapa penting kecepatan (waktu) memengaruhi skor akhir
- d_i : merepresentasikan batas waktu
- t_i : merepresentasikan waktu yang dibutuhkan untuk menyelesaikan latihan

Terakhir adalah komponen W_e , komponen ini merepresentasikan probabilitas seorang siswa mampu menyelesaikan latihan tertentu, yang dihitung berdasarkan rumus elo standard (Elo 1978):

$$W_e = \frac{1}{1 + 10^{\frac{R_i - 1 - D_{j-1}}{400}}}. \quad (\text{II.6})$$

II.3.6 Posisi Teknik dan Algoritma dalam Sistem Asesmen Adaptif Individual

Berbagai teknik yang telah dibahas di atas (IRT, Elo-rating, dll.) umumnya diimplementasikan dalam sebuah siklus sistem. Model konseptual siklus sistem yang dominan untuk asesmen adaptif saat ini adalah siklus yang berpusat pada pembelajar tunggal. Sebuah contoh representatif dari alur kerja ini diimplementasikan dalam sistem ProTuS oleh Vesin dkk. (2022), seperti yang ditunjukkan pada Gambar II.2.



Gambar II.2 Model Konseptual Alur Proses Sistem Adaptif Individual (diadaptasi dari Vesin dkk. (2022))

Menurut Vesin dkk. (2022) alur proses dalam model ini terdiri dari tiga tahap yang diulang secara terus-menerus:

1. **Sesi Pembelajaran (*Learning Sessions*):** Siswa berinteraksi dengan sumber daya pembelajaran yang disediakan, seperti membaca materi atau menyelesaikan latihan pengkodean.
2. **Asesmen Adaptif (*Adaptive Assessment*):** Saat siswa menyelesaikan aktivitas, sistem memperbarui peringkat mereka berdasarkan kinerja individu. Peringkat siswa (*student ratings*) dan tingkat kesulitan konten (*difficulty level of*

content) dihitung menggunakan metode seperti *Elo-rating* yang dimodifikasi.

3. **Rekomendasi (*Recommendation*):** Sistem kemudian merekomendasikan aktivitas pembelajaran lebih lanjut yang sesuai dengan kemahiran siswa saat ini.

Tahap modifikasi kesulitan konten pembelajaran mungkin tidak ada di semua sistem karena beberapa teknik seperti IRT mengharuskan kesulitan konten ditetapkan sebelumnya. Namun, secara umum akan melalui siklus seperti di atas, dan teknik serta algoritma yang dibahas sebelumnya berperan secara khusus dalam tahap asesmen adaptif.

II.4 Pembelajaran Kolaboratif dan CSCL

Tantangan untuk beralih dari model pedagogi yang berpusat pada instruktur menjadi berpusat pada siswa (Ryoo dan Winkelmann 2021) sejalan dengan penekanan Strategi Nasional KA Indonesia pada pentingnya ekosistem kolaboratif (Kelompok Kerja Penyusun Strategi Nasional untuk Kecerdasan Artifisial 2020). Dalam konteks pendidikan, filosofi kolaboratif ini sering dimediasi oleh teknologi melalui *Computer-Supported Collaborative Learning* (CSCL). Bagian ini membahas prinsip-prinsip dan tantangan dari pendekatan sosial ini, yang menjadi landasan untuk komponen ”sosial” dari sistem yang diusulkan.

II.4.1 Prinsip Pembelajaran Kolaboratif berbasis Teknologi

Alih-alih mendefinisikannya secara kaku, pendekatan modern melihat pembelajaran kolaboratif sebagai proses yang memanfaatkan teknologi untuk mendukung interaksi sosial. Prinsip-prinsip utamanya meliputi:

1. **Konstruksi Pengetahuan Sosial:** Sistem pembelajaran dapat didasarkan pada pendekatan konstruktivis sosial. Dalam model ini, pembelajaran muncul melalui interaksi baik dengan rekan yang berpengetahuan (*knowledgeable peers*) atau dengan sistem AI. Tujuannya adalah untuk mendorong formasi kelompok yang heterogen untuk memaksimalkan keragaman kognitif dan mendorong refleksi kritis (Halkiopoulos dan Gkintoni 2024).
2. **Interaksi dalam Komunitas Praktik (*Communities of Practice*):** Teknologi dapat memfasilitasi pembentukan *Communities of Practice* (CoP). Sistem *Computer-Supported Collaborative Work* (CSCW) atau proyek berbasis tim (*team-based projects*) memungkinkan pembelajar untuk berinteraksi dalam ruang tiga dimensi yang sama meskipun secara fisik berada di lokasi yang jauh (Ryoo dan Winkelmann 2021).

Meskipun prinsip pembentukan kelompok heterogen telah diakui kepentingannya,

tantangan teknis dalam sistem adaptif adalah menentukan standar kuantitatif yang baku untuk menilai apakah perbedaan kemampuan antar-siswa sudah cukup signifikan untuk disebut heterogen.

II.4.2 Pengukuran Heterogenitas Kelompok dan *Effect Size*

Dalam ranah ilmu perilaku dan pendidikan, pengukuran perbedaan antara dua kelompok atau individu tidak cukup hanya dengan melihat selisih nilai mentah (*raw score differences*), karena nilai tersebut sangat bergantung pada satuan skala yang digunakan. Untuk mengatasi hal ini, Cohen (1988) memperkenalkan konsep *Effect Size* (ES) sebagai indeks standar yang independen dari satuan pengukuran asal. Salah satu indeks ES yang paling fundamental dan banyak digunakan untuk membandingkan dua rata-rata adalah *Cohen's d*. Secara konseptual, *Cohen's d* didefinisikan sebagai selisih antara dua rata-rata populasi ($m_A - m_B$) yang dibagi dengan standar deviasi populasi (σ). Rasio ini merepresentasikan jarak antara dua rata-rata dalam satuan unit variabilitas standar, memberikan ukuran murni mengenai seberapa jauh dua distribusi nilai terpisah satu sama lain.

Dalam praktiknya, ketika parameter populasi tidak diketahui, nilai d diestimasi menggunakan statistik sampel. Cohen (1988) merumuskan penghitungan d untuk dua sampel independen dengan menggunakan *pooled standard deviation* (σ_{pooled}) sebagai penyebut, yang merupakan rata-rata akar kuadrat dari varians kedua kelompok. Rumus formal untuk menghitung jarak atau indeks perbedaan ini dinyatakan sebagai:

$$d = \frac{|\bar{x}_A - \bar{x}_B|}{\sigma_{pooled}} \quad (\text{II.7})$$

$$\sigma_{pooled} = \sqrt{\frac{(n_A - 1)s_A^2 + (n_B - 1)s_B^2}{n_A + n_B - 2}} \quad (\text{II.8})$$

dengan $\bar{x}_A$ dan $\bar{x}_B$ adalah nilai rata-rata (atau skor kemampuan individu) dari dua entitas yang dibandingkan, s_A^2 dan s_B^2 adalah varians masing-masing, serta n_A dan n_B adalah ukuran sampel. Jika diaplikasikan pada perbandingan antar-individu (dengan $n = 1$), penyebut dapat disederhanakan menjadi standar deviasi gabungan dari populasi referensi atau data historis sistem. Nilai d yang dihasilkan adalah nilai skalar tak berdimensi yang memungkinkan perbandingan yang adil lintas konteks yang berbeda.

Untuk memberikan makna interpretatif pada nilai numerik d , Cohen (1988) menetapkan standar konvensi yang telah menjadi rujukan universal dalam analisis kuantitatif. Konvensi ini dirancang untuk memetakan besaran statistik ke dalam dampak kualitatif yang dapat diamati di dunia nyata.

- **Efek Kecil ($d = 0.2$):** Perbedaan yang nyata namun sulit dideteksi tanpa analisis statistik yang cermat.
- **Efek Sedang ($d = 0.5$):** Perbedaan yang cukup besar untuk dapat dilihat oleh mata telanjang pengamat yang berpengalaman (*visible to the naked eye*).
- **Efek Besar ($d = 0.8$):** Perbedaan yang sangat mencolok, setara dengan perbedaan tinggi badan antara remaja usia 13 dan 18 tahun.

Standar operasional ini memberikan landasan teoretis yang kokoh untuk menetapkan ambang batas (*threshold*) dalam menentukan apakah dua entitas (atau kelompok) dapat dikategorikan "berbeda secara signifikan" atau heterogen dalam konteks intervensi pendidikan.

II.4.3 Aktivitas Pembelajaran Sosial dan Dampaknya

Selain prinsip-prinsip umum yang telah dibahas pada Subbab II.4.1, penting untuk mengidentifikasi bentuk-bentuk aktivitas pembelajaran sosial spesifik yang telah terbukti secara empiris memiliki dampak positif terhadap hasil belajar. Aktivitas-aktivitas inilah yang menjadi kandidat utama untuk diintegrasikan dan dinilai dalam sebuah sistem adaptif.

1. **Penilaian sejawat (*Peer Assessment*):** Penilaian sejawat adalah aktivitas pendidikan yang mengajak siswa saling menilai pekerjaan rekannya, artinya dalam penilaian ini "penilai (*assessor*) dan yang dinilai (*assessed*) memiliki status yang sama" (Ihichr dkk. 2024). Evaluasi terhadap kinerja asesor dalam *peer assessment* tidak cukup hanya didasarkan pada akurasi skor (*rating accuracy*), tetapi juga harus meninjau kualitas umpan balik tekstual yang diberikan. Wu dan Schunn (2020) mengusulkan kerangka kerja yang membedah fitur umpan balik ke dalam dua dimensi utama: dimensi kognitif dan dimensi afektif. Dimensi kognitif (*cognitive feedback*) berkaitan dengan substansi perbaikan tugas, yang terdiri atas empat kategori spesifik: (1) *Identification*, yaitu kemampuan asesor mendeteksi letak kesalahan; (2) *Explanation*, yaitu penyediaan alasan logis mengapa suatu bagian dianggap salah; (3) *Suggestion*, yaitu pemberian saran eksplisit untuk perbaikan; dan (4) *Solution*, yaitu penyediaan contoh koreksi langsung.

Di sisi lain, dimensi afektif (*affective feedback*) mencakup nada emosional dan interpersonal yang digunakan asesor, yang terbagi menjadi kategori *Pra-*

ise (pujian yang memvalidasi kelebihan) dan *Hedges* (penggunaan bahasa penyangga untuk memperhalus kritik). Dalam sistem yang berorientasi pada pembelajaran kolaboratif, keberadaan fitur kognitif tingkat tinggi seperti *Explanation* dan *Suggestion* sering kali dijadikan indikator utama kompetensi asesor, karena elemen-elemen inilah yang terbukti memicu perbaikan revisi yang signifikan pada penerima umpan balik, sekaligus merefleksikan kedalaman pemahaman konseptual dari pemberi umpan balik (Wu dan Schunn 2020).

Manfaat pedagogis dari penilaian sejawat sering diasumsikan berasal dari umpan balik yang diterima siswa. Namun, sebuah studi pemodelan jalur (*path model*) oleh Lu dan Zhang (2012) memberikan wawasan yang lebih mendalam mengenai mekanisme efektivitasnya. Studi tersebut menemukan bahwa manfaat kognitif terbesar **tidak diterima oleh siswa yang dinilai (*assessee*)**, melainkan oleh **siswa yang menilai (*assessor*)**. Ditemukan bahwa jumlah umpan balik kognitif yang *diberikan* (*Cognitive Feedback to Peers / CTP*) oleh seorang penilai secara signifikan memprediksi skor proyek akhir dari penilai itu sendiri. Lu dan Zhang (2012) berargumen bahwa hal ini terjadi karena tindakan menilai "mengharuskan penilai untuk terlibat dalam aktivitas kognitif yang lebih menuntut" dan "mendapatkan wawasan tentang pekerjaan mereka sendiri" saat mengkritik pekerjaan rekan-rekannya. Sebaliknya, jumlah umpan balik kognitif yang *diterima* (*Cognitive Feedback from Peers / CFP*) *tidak* menunjukkan korelasi signifikan dengan skor akhir penerima.

2. **Pembelajaran Berbasis Proyek (*Project-Based Learning*):** Pembelajaran berbasis proyek (PBL) adalah model pembelajaran inkuiri yang berpusat pada siswa, dengan tujuan "menghasilkan sebuah karya proyek yang lengkap" untuk memecahkan masalah dunia nyata (Zhang dan Ma 2023). Berbeda dengan pembelajaran tradisional, PBL menempatkan siswa dalam peran aktif untuk berkolaborasi, mengintegrasikan berbagai disiplin ilmu, dan menerapkan pengetahuan (Ryoo dan Winkelmann 2021). Sebuah meta-analisis oleh Zhang dan Ma (2023) terhadap 66 studi eksperimental menemukan bahwa PBL secara signifikan "meningkatkan hasil belajar siswa" dibandingkan dengan model pengajaran tradisional. Dampak positif ini terukur pada tiga dimensi luaran pembelajaran, yaitu "pencapaian akademik (*academic achievement*), sikap afektif (*affective attitudes*), dan keterampilan berpikir (*thinking skills*)" (Zhang dan Ma 2023).
3. **Pendampingan Sejawat (*Peer Mentoring*):** *Peer mentoring* adalah mekanisme "bimbingan individual yang diberikan oleh siswa senior untuk mem-

bantu siswa lain” (Le, Sok, dan Heng 2024). Aktivitas ini dirancang untuk membantu siswa baru (*mentee*) dalam menavigasi tantangan transisi ke pendidikan tinggi, baik secara akademik maupun sosial. Sebuah tinjauan sistematis baru-baru ini yang mencakup 27 studi empiris mengidentifikasi empat kategori manfaat fundamental dari *peer mentoring* bagi *mentee*. Manfaat tersebut adalah: (1) peningkatan ”kinerja akademik” (*academic performance*), (2) peningkatan ”tingkat retensi” (*retention rates*) atau persistensi, (3) peningkatan ”kesejahteraan emosional dan psikologis” (*emotional and psychological wellbeing*), dan (4) ”integrasi sosial” (*social integration*) yang lebih baik di lingkungan kampus (Le, Sok, dan Heng 2024).

4. **Sesi Diskusi Terbuka:** Interaksi sosial langsung melalui diskusi juga terbukti berdampak pada hasil belajar. Sebuah studi oleh Daif-Allah dan Khan (2016) menginvestigasi dampak dari ”Sesi Diskusi Terbuka” (*Open Discussion Sessions*) yang diadakan sebagai kegiatan ekstrakurikuler untuk meningkatkan kemampuan komunikasi lisan siswa. Hasil studi menunjukkan adanya ”perkembangan signifikan dalam kemampuan berbicara siswa”. Keberhasilan ini diatribusikan pada faktor-faktor kunci dari desain aktivitas tersebut, yaitu penyediaan ”lingkungan belajar yang santai tanpa rasa khawatir” (*relaxed learning environment void of worry*) dan ”keterlibatan aktif dengan situasi komunikatif nyata” (*active involvement with real communicative situations*) (Daif-Allah dan Khan 2016).
5. **Bermain Peran (*Role-Playing*):** metode bermain peran adalah ”metode pengajaran simulasi situasional”. Pada metode ini, siswa diminta untuk mengambil peran spesifik untuk mensimulasikan skenario dunia nyata. Pendekatan ini memindahkan fokus dari transmisi pengetahuan teoretis ke penerapan praktis dan pengembangan keterampilan. Sebuah meta-analisis yang mensintesis 22 ukuran efek dari 12 artikel menemukan bahwa pengajaran menggunakan metode bermain peran memiliki ”efek positif yang signifikan” ($ES=0.818$) pada siswa dibandingkan dengan kelompok kontrol yang menggunakan pengajaran tradisional. Secara khusus, ditemukan bahwa metode bermain peran memiliki dampak paling signifikan pada peningkatan ”Keterampilan” (*Skills*) siswa (Fu dan Li 2025).

II.4.4 Tantangan dalam Menilai Kolaborasi

Meskipun manfaat pedagogisnya jelas, menilai pembelajaran kolaboratif secara adil menghadirkan tantangan yang signifikan. Masalah utamanya adalah bagaimana mengukur kontribusi individu secara akurat di dalam upaya kelompok.

Salah satu tantangan utama adalah bahwa metode untuk menilai kinerja dalam kelompok yang tujuannya adalah pemecahan masalah secara kreatif, perlu bisa mengukur bagaimana setiap orang secara personal berkontribusi pada kelompok mereka, dan bagaimana efek dari kontribusi individual tersebut terhadap kuantitas maupun kualitas hasil akhir dari penyelesaian masalah (Ryoo dan Winkelmann 2021).

Untuk mengatasi ini, *peer assessment* (penilaian sejawat) sering digunakan. Ini dijelaskan sebagai aktivitas pendidikan yang menghadirkan penilai (*assessor*) dan yang dinilai (*assessed*) dalam status yang sama, dan masing-masing menilai hasil belajar, kualitas, dan level satu sama lain (Ihichr dkk. 2024). Studi oleh Ihichr dkk. (2024) mencatat bahwa siswa mendapat lebih banyak manfaat dari bertindak sebagai penilai daripada hanya dinilai.

Tantangan kedua, yang secara khusus relevan dengan penelitian ini, adalah risiko "personalisasi berlebih" (*over-personalization*) dalam sistem adaptif berbasis AI. Sistem yang terlalu fokus pada optimasi jalur belajar individu dapat menyebabkan pembelajar yang mendapat manfaat dari pembelajaran bersama (*shared learning*) akan terasingkan dalam sistem. Personalisasi berlebih ini kemungkinan akan menjadi penghalang ketika siswa seharusnya dapat memperoleh manfaat dari aspek komunal pembelajaran. Oleh karena itu, sistem asesmen adaptif modern harus mampu menyeimbangkan antara personalisasi individu dengan fasilitasi interaksi sosial yang bermakna (Halkiopoulou dan Gkintoni 2024).

II.5 Upaya Integrasi Penilaian Personal dalam Lingkungan Kolaboratif yang Sudah Ada Saat Ini


Tinjauan literatur menunjukkan bahwa sebagian besar penelitian dan implementasi sistem pembelajaran adaptif hingga saat ini berfokus secara dominan pada pembelajar individu. Sistem *e-learning* yang ada seringkali dirancang untuk mengadaptasi konten dan urutan penyampaiannya sesuai dengan kemampuan pembelajar secara individual (Halkiopoulou dan Gkintoni 2024). Fokus pada personalisasi ini terlihat jelas dalam model-model asesmen dominan seperti *Item Response Theory* (IRT), *Bayesian Knowledge Tracing* (BKT), dan *Deep Knowledge Tracing* (DKT), yang pada intinya memodelkan keadaan pengetahuan laten seorang siswa tunggal (Minn 2022).

Meskipun personalisasi ini menawarkan manfaat yang substansial, Halkiopoulou dan Gkintoni (2024) memperingatkan adanya risiko "personalisasi berlebih" (*over-personalization*). Pendekatan yang terlalu terindividualisasi ini dapat menciptakan

situasi yang menyebabkan pembelajar yang seharusnya bisa mendapat manfaat dari pembelajaran bersama (*shared learning*) malah terasingkan, sehingga menghambat perolehan manfaat dari aspek komunal pembelajaran.

Beberapa penelitian memang telah mengeksplorasi penggunaan AI dalam konteks kolaboratif, tetapi seringkali secara terpisah dari *loop* asesmen adaptif inti. Sebagai contoh, Nalli, Amendola, dan Smith (2022) menggunakan algoritma *Artificial Intelligence* (secara spesifik, teknik *clustering*) untuk membantu pengajar dalam pembentukan kelompok heterogen. Dalam studi ini, AI digunakan sebagai alat bantu persiapan (*setup tool*) yang efektif untuk formasi kelompok, bukan sebagai mesin yang secara dinamis menilai kolaborasi atau mengadaptasi konten secara *real-time* berdasarkan interaksi kelompok.

Upaya yang lebih dekat dengan integrasi ini adalah *Open Social Student Modeling* (OSSM) yang diperkenalkan oleh Brusilovsky dkk. (2016).



Gambar II.3 Model Konseptual Antarmuka Pembelajaran Sosial (OSSM)
(diadaptasi dari Brusilovsky dkk. (2016))


Dalam implementasinya pada sistem MasteryGrids, OSSM melengkapi aspek kognitif dengan aspek sosial melalui antarmuka yang menampilkan visualisasi perbandingan kinerja "Me vs group" (Saya vs grup) dan baris "Group" (Grup). Meskipun studi mereka menemukan bahwa fitur eksplorasi sosial ini dapat meningkatkan pembelajaran, terutama bagi siswa dengan pengetahuan awal rendah, pendekatan ini pada utamanya bersifat visualisasi sosial. Brusilovsky dkk. (2016) menempatkan aspek sosial sebagai *output* untuk memotivasi siswa, namun tidak merinci bagaimana data perbandingan sosial ini diintegrasikan kembali sebagai *input* ke dalam algoritma asesmen inti (seperti *Elo-rating* atau BKT) untuk mengubah perhitungan kemahiran individu secara dinamis atau merekomendasikan intervensi kolaboratif.

II.6 Upaya Penyelesaian Masalah *Over-Personalization* yang Ada Saat Ini

Masalah *over-personalization* telah menjadi perhatian utama dalam penelitian sistem rekomendasi modern karena dampaknya dalam menciptakan *filter bubbles* dan *echo chambers*. Untuk mengatasi isolasi pengguna ini tanpa mengorbankan relevansi secara signifikan, peneliti telah mengembangkan berbagai pendekatan teknis yang inovatif. Tiga pendekatan yang paling menonjol dan relevan melibatkan penggunaan rekomendasi berbasis kelompok (*Group Recommender Systems*), pemberian kendali kepada pengguna (*User-Controllable Systems*), dan pemodelan komunitas secara implisit (*Implicit Community Modeling*).

II.6.1 Sistem Rekomendasi yang Dapat Dikontrol Pengguna (*User-Controllable Recommender Systems*)

Pendekatan pertama adalah pendekatan yang dikenal sebagai *User-Controllable Recommender System* (UCRS), pendekatan ini menerapkan sistem yang memungkinkan pengguna memiliki hak untuk memutuskan apakah ingin menghindari *filter bubble*, sehingga bisa melakukan pemilihan "bubble" mana yang akan menghindari. Secara fungsional, Wang dkk. (2022) menjelaskan bahwa UCRS dapat memperingatkan pengguna jika mereka terjebak dalam *filter bubble*, mendukung empat jenis perintah kontrol bagi pengguna untuk memitigasi *bubble* pada tingkat granularitas (tingkat kedetailan) yang berbeda (*fine-grained* dan *coarse-grained*), serta merespons kontrol tersebut dan menyesuaikan rekomendasi secara langsung (*on the fly*). Sistem ini menyediakan perintah kontrol terkait fitur pengguna atau fitur item, seperti perintah *fine-grained* untuk meningkatkan item yang disukai oleh kelompok pengguna lain atau item dalam kategori target tertentu (Wang dkk. 2022).



Gambar II.4 Model Konseptual Sistem Rekomendasi yang Dapat Dikontrol Pengguna (UCRS) (diadaptasi dari Wang dkk. (2022))

Tantangan teknis utama dalam merespons kontrol pengguna adalah memblokir efek dari representasi pengguna yang sudah kedaluwarsa (*out-of-date*), yang mengandung informasi historis yang tidak konsisten dengan perintah kontrol. Untuk mengatasi hal ini, dikembangkan kerangka kerja **User Controllable Inference** (UCI) yang ditingkatkan dengan kausalitas, yang memeriksa prosedur pembuatan rekomendasi dari pandangan kausal dan memanfaatkan inferensi kontrafaktual (*counterfactual inference*) untuk memitigasi efek dari representasi pengguna yang kedaluwarsa tersebut (Wang dkk. 2022). Secara khusus, UCI membayangkan dunia kontrafaktual yang di dalamnya representasi pengguna yang kedaluwarsa dibuang, dan mengestimasi efeknya sebagai perbedaan antara dunia faktual dan kontrafaktual, lalu mengurangi efek tersebut dalam prediksi akhir.

II.6.2 Pendekatan Berbasis Kelompok (*Group Recommender Systems*)


Pendekatan kedua menggunakan **Group Recommender Systems** (GRS) untuk memitigasi masalah *filter bubble* dan *echo chamber* dengan fokus pada kelompok pengguna yang besar. Dokoupil (2022) mengusulkan aplikasi baru GRS yang melibatkan konstruksi kelompok pengguna skala besar dan berfokus pada keadilan jangka panjang (*long-term fairness*) dari kelompok-kelompok ini, yang berbeda dengan penelitian yang sudah ada sebelumnya yang berkonsentrasi pada kelompok kecil yang bersifat sementara. GRS perlu mengatasi heterogenitas preferensi anggota kelompok dan menghasilkan rekomendasi dengan utilitas keseluruhan yang tinggi sam-

bil tetap mempertimbangkan rasa keadilan di antara anggota kelompok (Dokoupil 2022).

Secara spesifik untuk skenario pengguna tunggal, pendekatan ini mengusulkan pembangunan "*virtual groups*" atau kelompok virtual yang kemudian diteruskan ke GRS untuk mendapatkan rekomendasi akhir bagi pengguna tersebut. Hipotesis awalnya adalah bahwa anggota kelompok virtual seharusnya fokus pada topik yang serupa, tetapi dapat memiliki sikap yang beragam terhadap topik tersebut (Dokoupil 2022). Dengan menerapkan GRS pada kelompok yang seimbang (mungkin besar) alih-alih rekomendasi individu, pendekatan ini bertujuan untuk meningkatkan pluralitas opini atau mengurangi polarisasi, sehingga membantu memecahkan masalah *filter bubble*. Meskipun demikian, perlu dicatat bahwa pekerjaan ini masih merupakan rencana penelitian untuk aplikasi baru GRS, sehingga penulis masih baru merencanakan investigasi terhadap efek ukuran kelompok pada kinerja GRS serta evaluasi menggunakan grup yang dihasilkan secara sintetis maupun data publik (Dokoupil 2022).

II.6.3 Pemodelan Komunitas Implisit untuk Memecahkan *Echo Chamber*

Pendekatan ketiga adalah **FRediECH** (*A Friend Recommender for breaking Echo Chambers*), sebuah pendekatan rekomendasi teman yang sadar akan *echo chamber* dan bertujuan merekomendasikan teman yang relevan dan beragam dari luar jangkauan pengaruh *echo chamber* pengguna. Pendekatan ini didasarkan pada pembelajaran representasi pengguna dan *echo chamber* secara dinamis berdasarkan konten yang dibagikan dan interaksi komunitas pengguna, alih-alih bergantung pada penemuan komunitas secara eksplisit yang mungkin kompleks secara komputasi (Tommasel, Rodriguez, dan Godoy 2021). Masalah rekomendasi diformulasikan untuk mempelajari fungsi yang mengestimasi kekuatan interaksi potensial antar pengguna berdasarkan interaksi masa lalu dan konten yang dibagikan, pada formulasi ini kekuatan interaksi potensial yang lebih tinggi menunjukkan keseimbangan yang lebih baik antara relevansi pengguna dan jaraknya dari *echo chamber* pengguna lain.



Gambar II.5 Diagram Arsitektur FRediECH (diadaptasi dari Tommasel, Rodriguez, dan Godoy (2021))

Pada gambar II.5 terlihat arsitektur FRediECH yang terinspirasi oleh **Graph Convolutional Network** (GCN) dan arsitektur **Deep & Wide**, yang menggabungkan kesadaran *echo chamber* dan representasi pengguna untuk menyeimbangkan relevansi, keragaman, dan kebaruan rekomendasi. Tommasel, Rodriguez, dan Godoy (2021) menggunakan GCN paralel untuk mempelajari kontribusi spesifik dari jenis interaksi tertentu (seperti *reply*, *mention*, atau *retweet*) terhadap set lengkap hubungan pengguna, kemudian menggabungkan outputnya untuk menghasilkan representasi pengguna perantara. Fungsi kerugian (*loss function*) didefinisikan berdasarkan jarak antara pengguna dan jumlah interaksi, yang bertujuan untuk memberikan bobot pada interaksi sedemikian rupa sehingga interaksi antara pengguna yang berasal dari *echo chamber* yang berbeda membawa bobot yang lebih tinggi daripada interaksi dalam *echo chamber* yang sama, sehingga mempromosikan keragaman rekomendasi dengan mempelajari struktur komunitas secara implisit (Tommasel, Rodriguez, dan Godoy 2021).

II.6.4 Mitigasi Dampak *Echo Chamber* Melalui *Constraint-Based Re-ranking*

Salah satu pendekatan algoritmik terbaru yang secara spesifik menangani dampak rekomendasi terhadap perilaku pengguna adalah kerangka kerja yang diusulkan oleh Biasio dkk. (2023). Penelitian ini membedakan dirinya dari pendekatan diversifikasi umum dengan memfokuskan pada perlindungan kelompok pengguna "sensitif" (*sensitive users*) dari paparan berlebih terhadap konten "berpengaruh" (*influential items*) yang dapat memperburuk kondisi perilaku mereka, seperti polarisasi ekstrem

atau isolasi sosial.

Dalam model Biasio dkk. (2023), masalah *echo chamber* tidak dipandang seragam untuk semua pengguna, melainkan diklasifikasikan berdasarkan kerentanan:

- **Pengguna Sensitif (*Sensitive Users*):** Kelompok pengguna yang perilakunya rentan dipengaruhi secara negatif oleh pola konsumsi konten yang homogen atau bias.
- **Item Berpengaruh (*Influential Items*):** Kategori konten yang memiliki dampak signifikan terhadap perilaku pengguna sensitif. Item ini dibagi menjadi dua:
 1. *Controversial Items*: Item yang jika dikonsumsi berlebihan dapat memperburuk isolasi atau perilaku negatif.
 2. *Favorable Items*: Item yang dapat memberikan dampak positif atau memecah isolasi (*bubble*) jika direkomendasikan dengan proporsi yang cukup.

Pendekatan ini sangat relevan untuk konteks pembelajaran adaptif karena "pengguna sensitif" dapat dipetakan sebagai siswa yang terisolasi secara akademik, dan "favorable items" sebagai interaksi dengan rekan yang memiliki kompetensi berbeda (heterogen).

Untuk memitigasi dampak negatif rekomendasi pada pengguna sensitif tanpa memerlukan pelatihan model ulang, Biasio dkk. (2023) mengusulkan algoritma *greedy re-ranking*. Algoritma ini bekerja pada tahap pasca-pemrosesan dengan menyusun ulang daftar skor prediksi awal ($\hat{r}_u$) agar memenuhi batasan proporsi item tertentu.

Berikut adalah pseudocode dari algoritma tersebut sebagaimana didefinisikan dalam penelitian aslinya:

Kode II.1 Algoritma Re-ranking

ALGORITHM Re-ranking

INPUT:

u : User identifier
S : Set of sensitive users
r_hat : Scores predicted by backbone model for user u
alpha : Minimum percentage of favorable items allowed
beta : Maximum percentage of controversial items allowed
k : Number of items to be recommended

OUTPUT:

Y_star : Top-k items to recommend to user u

BEGIN

IF u NOT IN S THEN

RETURN Argsort(r_hat, order='descending')[0:k]

ELSE

Y_star <- EmptySet

SortedItems <- Sort(r_hat, order='descending')

FOR EACH item j IN SortedItems DO

IF Size(Y_star) < k THEN

CondAlpha <- ((f_j + Sum(f_i for i in Y_star))
/ k) >= alpha

CondBeta <- ((c_j + Sum(c_i for i in Y_star))
/ k) <= beta

IF CondAlpha AND CondBeta THEN

Add j to Y_star

END IF

ELSE

BREAK

END IF

END FOR

RETURN Y_star

END IF

END

END ALGORITHM

Secara matematis, algoritma memastikan bahwa probabilitas terpilihnya suatu item y_i dalam rekomendasi untuk pengguna sensitif ($s_u = 1$) memenuhi pertidaksamaan

berikut.

$$\mathbb{P}(y_i = 1 \mid s_u = 1, f_i = 1) \geq \alpha \quad (\text{II.9})$$

$$\mathbb{P}(y_i = 1 \mid s_u = 1, c_i = 1) \leq \beta \quad (\text{II.10})$$

dengan:

- Persamaan (II.9) menetapkan bahwa proporsi item *favorable* (yang memecah isolasi) harus lebih besar atau sama dengan ambang batas α .
- Persamaan (II.10) menetapkan bahwa proporsi item *controversial* (yang memperburuk isolasi) harus lebih kecil atau sama dengan ambang batas β .

Algoritma *re-ranking* ini bekerja dengan menyusun ulang daftar rekomendasi $\mathcal{Y}_{u,k}$ secara iteratif. Pada setiap langkah penambahan item ke dalam daftar rekomendasi final, algoritma memeriksa apakah penambahan item tersebut akan melanggar batasan α atau β .

- Jika daftar rekomendasi saat ini kekurangan item *favorable* (di bawah ambang α), algoritma akan secara paksa mengambil item *favorable* dari daftar cadangan, meskipun skor relevansinya sedikit lebih rendah, untuk menggantikan item non-favorable.
- Mekanisme ini menjamin terjadinya ”eksposur paksa” (*forced exposure*) terhadap konten yang beragam, yang merupakan syarat utama untuk memecahkan *filter bubble* secara efektif (Biasio dkk. 2023).

Keunggulan utama pendekatan ini adalah sifatnya yang *model-agnostic* dan efisien secara komputasi karena menggunakan pendekatan *greedy* pada tahap *post-processing*, sebagaimana dijelaskan secara teknis oleh Biasio dkk. (2023). Hal ini membuatnya lebih layak diimplementasikan pada kondisi data terbatas (*cold-start*) dibandingkan metode berbasis *Deep Learning* yang membutuhkan pelatihan ekstensif.

II.6.5 Evaluasi Efektivitas Pembelajaran dengan *Normalized LearningGain*

Dalam ranah penelitian pendidikan fisika dan teknologi pembelajaran, pengukuran efektivitas intervensi instruksional sering kali menghadapi tantangan bias yang disebabkan oleh perbedaan tingkat pengetahuan awal siswa. Untuk mengatasi hal ini, Richard Hake memperkenalkan konsep *average normalized gain* (g) sebagai metrik standar. Secara teoretis, *normalized gain* didefinisikan sebagai rasio antara pening-

katan skor aktual yang dicapai (*actual gain*) terhadap peningkatan skor maksimum yang mungkin dicapai (*maximum possible gain*). Penggunaan metrik ini bertujuan untuk memisahkan efek pembelajaran dari pengaruh skor *pre-test*, sehingga memungkinkan perbandingan yang objektif antara populasi siswa yang memiliki latar belakang kemampuan yang heterogen (Nissen dkk. 2018).

Secara matematis, perhitungan *normalized gain* untuk rata-rata kelas atau individu dinyatakan dalam persamaan berikut, dengan asumsi skor dinyatakan dalam persentase:

$$g = \frac{\%post - \%pre}{100 - \%pre} \quad (II.11)$$

dengan %pre merepresentasikan persentase skor pada tes awal sebelum instruksi diberikan, dan %post adalah persentase skor pada tes akhir. Coletta dan Steinert (2020) menegaskan bahwa metrik ini memiliki keunggulan teoretis dibandingkan perhitungan selisih skor mentah atau *effect size* standar (seperti Cohen's *d*), terutama dalam menangani distribusi data yang mengalami *floor effect* atau *ceiling effect* ekstrem, di mana siswa dengan skor awal tinggi memiliki ruang peningkatan yang lebih sempit dibandingkan siswa dengan skor rendah.

Sebagai standar interpretasi efektivitas yang berlaku umum dalam literatur, Hake menetapkan kriteria ambang batas untuk mengkategorikan tingkat keberhasilan pembelajaran. Nilai *g* diklasifikasikan ke dalam tiga kategori: (1) **Rendah** (*Low-g*) jika $g < 0.3$; (2) **Sedang** (*Medium-g*) jika $0.3 \leq g < 0.7$; dan (3) **Tinggi** (*High-g*) jika $g \geq 0.7$. Klasifikasi ini menyediakan kerangka kerja komparatif yang konsisten bagi para peneliti untuk mengevaluasi apakah sebuah metode pedagogis mampu menghasilkan peningkatan pemahaman konsep yang substansial terlepas dari kesulitan materi yang diajarkan (Coletta dan Steinert 2020).

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Mayoritas sistem asesmen adaptif yang ada saat ini dibangun di atas asumsi bahwa pembelajaran adalah proses soliter. Algoritma pelacakan pengetahuan (*knowledge tracing*) yang dominan bekerja dengan memproses data interaksi biner (benar/salah) antara siswa dan mesin secara eksklusif (Minn 2022).

Implikasi dari desain ini adalah terjadinya *algorithmic blindness* terhadap konteks sosial. Sistem mampu memodelkan kemahiran individu dengan presisi tinggi, namun ”buta” terhadap fakta bahwa siswa mungkin terjebak dalam isolasi materi atau *filter bubble* akademik, hanya mengerjakan tipe soal yang dikuasai dan tidak pernah terekspos pada perspektif rekan sejawat (Halkiopoulos dan Gkintoni 2024). Akibatnya, sistem berisiko memberikan skor kompetensi tinggi pada siswa yang sebenarnya rapuh secara kolaboratif, menciptakan fenomena ”kompetensi semu”.

Dalam kondisi saat ini, aktivitas sosial seringkali hanya ditempatkan sebagai fitur tambahan (*add-on*) yang berjalan paralel namun terpisah dari mesin asesmen utama. Data berharga dari interaksi sosial seperti kemampuan siswa dalam mengevaluasi pekerjaan orang lain atau memberikan argumen seringkali terbuang dan tidak dikonversi menjadi sinyal kompetensi yang dapat mengubah rekomendasi materi (Ihichr dkk. 2024).

Upaya yang ada untuk mengatasi masalah isolasi pembelajaran sejauh ini cenderung mengandalkan inisiatif pengguna, seperti pendekatan *User-Controllable Recommender Systems* (UCRS) (Wang dkk. 2022) atau visualisasi sosial (OSSM) (Brusilovsky dkk. 2016). Namun, pendekatan ini memiliki kelemahan fundamental dalam konteks pendidikan: pendekatan ini berasumsi bahwa pengguna menyadari bahwa mereka sedang terisolasi.

Dalam realitas algoritma adaptif, fenomena *over-personalization* yang terealisasi dengan gejala *filter bubble* atau *echo-chamber* seringkali bersifat tidak terlihat (*invisible*). Sistem secara otomatis menyaring konten yang tidak sesuai dengan profil historis, sehingga siswa tidak pernah terekspos pada opsi alternatif dan menganggap bahwa materi yang mereka terima adalah satu-satunya yang tersedia. Oleh karena itu, menyerahkan kendali mitigasi sepenuhnya kepada pengguna berisiko tidak efektif karena pengguna tidak dapat memilih apa yang tidak mereka lihat. Sistem saat ini kekurangan mekanisme intervensi otomatis yang mampu "memaksa" terjadinya diversifikasi interaksi ketika pola isolasi terdeteksi oleh algoritma. Dari analisis kondisi di atas, disimpulkan bahwa menambahkan fitur kolaborasi konvensional tidak akan menyelesaikan masalah *over-personalization* selama mesin asesmennya masih bekerja secara terisolasi.

Kebutuhan mendesak saat ini adalah melakukan rekayasa ulang (*re-engineering*) pada arsitektur asesmen. Diperlukan sebuah sistem yang mampu memperlakukan aktivitas sosial setara dengan aktivitas pengerjaan soal. Sistem harus memiliki kapabilitas untuk: (1) mengkuantifikasi aktivitas kolaboratif menjadi data kompetensi yang terukur, dan (2) menggunakan data tersebut untuk melakukan intervensi aktif terhadap rekomendasi yang diberikan kepada siswa. Hanya dengan mengintegrasikan kedua jalur data inilah sistem dapat memitigasi risiko isolasi pembelajaran secara sistematis.

III.2 Analisis Kebutuhan

Berdasarkan analisis kondisi saat ini pada Subbab III.1, sistem yang dibutuhkan harus mampu menjembatani keterpisahan antara personalisasi individu dengan lingkungan sosialnya untuk memitigasi risiko *over-personalization*. Kebutuhan ini dirumuskan tanpa membatasi teknik implementasi spesifik, guna memungkinkan eksplorasi berbagai alternatif solusi (seperti *peer assessment*, *mentoring*, atau rekomendasi jejaring) pada tahap pemilihan solusi.

III.2.1 Kebutuhan Fungsional

Daftar kebutuhan fungsional sistem dari sisi pengguna (siswa) dan logika sistem disajikan pada Tabel III.1.

Tabel III.1 Kebutuhan Fungsional (FR) Sistem

Kode	Deskripsi Kebutuhan Fungsional
Interaksi Pengguna (Siswa)	
FR-01	Sistem harus menyediakan mekanisme otentikasi bagi siswa untuk mengakses lingkungan pembelajaran personal mereka.
FR-02	Sistem harus menyajikan materi pembelajaran yang telah disesuaikan tingkat kesulitannya dengan kemahiran siswa saat ini.
FR-03	Sistem harus memfasilitasi interaksi pembelajaran antar-pengguna yang memungkinkan terjadinya pertukaran informasi atau kolaborasi akademik di dalam platform.
FR-04	Sistem harus menyediakan informasi mengenai konteks sosial pembelajaran (misalnya, aktivitas komunitas atau capaian kolektif) untuk membangun kesadaran sosial (<i>social awareness</i>).
Logika Adaptasi & Pemrosesan Data (Sistem)	
FR-05	Sistem harus memiliki algoritma untuk mengestimasi tingkat kemahiran pengetahuan individu siswa secara dinamis berdasarkan riwayat aktivitasnya.
FR-06	Sistem harus mampu mengkuantifikasi data interaksi sosial (dari FR-03) menjadi parameter numerik yang dapat diproses lebih lanjut (misalnya, skor keterlibatan atau skor kinerja kolaboratif).
FR-07	Sistem harus memiliki mekanisme untuk menggabungkan parameter kemahiran individu (FR-05) dan parameter sosial (FR-06) dalam satu model komputasi terpadu.
FR-08	Sistem harus menggunakan hasil penggabungan model (FR-07) untuk menentukan materi atau aktivitas berikutnya yang paling optimal bagi siswa.
FR-09	Sistem harus mampu merekomendasikan intervensi sosial spesifik (misalnya, merekomendasikan orang untuk berinteraksi atau topik untuk didiskusikan) guna mencegah isolasi pembelajaran.

III.2.2 Kebutuhan Nonfungsional

Kebutuhan nonfungsional disesuaikan untuk mendukung interaksi sosial yang responsif tanpa menentukan metode spesifik.

Tabel III.2 Kebutuhan Nonfungsional (NFR) Sistem

Kode	Deskripsi Kebutuhan Nonfungsional
NFR-01	(Usability) Antarmuka interaksi sosial harus terintegrasi secara intuitif dengan materi pembelajaran, meminimalkan beban kognitif siswa saat berpindah antara belajar mandiri dan berkolaborasi.
NFR-02	(Interpretability) Sistem harus mampu memberikan indikasi alasan di balik rekomendasi (baik materi maupun interaksi sosial) agar dapat dipahami oleh siswa.
NFR-03	(Performance) Pembaruan model pengguna (baik skor individu maupun sosial) harus terjadi dalam waktu nyata (<i>near real-time</i>) setelah interaksi selesai dilakukan.
NFR-04	(Scalability) Sistem harus mampu menangani konkurensi interaksi sosial dari satu kelas (± 50 pengguna) secara simultan.
NFR-05	(Privacy) Mekanisme interaksi sosial harus dirancang sedemikian rupa sehingga data privasi spesifik (seperti nilai ujian mentah) tidak terekspos ke pengguna lain tanpa izin.
NFR-06	(Access) Sistem dapat diakses melalui peramban web standar.

III.2.3 Pemetaan Kebutuhan

Tabel III.3 memetakan tujuan penanganan masalah ke fungsi spesifik yang telah digeneralisasi.

Tabel III.3 Pemetaan Masalah dan Kebutuhan Fungsional

Fokus Penanganan Masalah	Implementasi Fungsional (FR)
Model Kompetensi Individu	FR-02, FR-05
Fasilitasi Interaksi Sosial	FR-01, FR-03, FR-04
Kuantifikasi Aspek Sosial	FR-06
Integrasi Model	FR-07
Adaptasi	FR-08, FR-09

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Untuk menjawab kebutuhan sistem dalam memitigasi *over-personalization*, diperlukan pemilihan komponen teknologi yang tidak hanya akurat, tetapi juga fleksibel untuk diintegrasikan. Pemilihan solusi dilakukan pada tiga dimensi utama: (1) teknik asesmen kemahiran individu, (2) teknik interaksi dan asesmen sosial, dan (3) teknik spesifik pencegahan *echo chamber*.

III.3.1.1 Alternatif Teknik Asesmen Kemahiran Individu (R1)

Komponen ini berfungsi memodelkan kompetensi siswa. Dalam konteks pencegahan *over-personalization*, kriteria utamanya adalah apakah model tersebut cukup fleksibel untuk "diintervensi" oleh parameter sosial tanpa merusak integritas matematisnya.

- **Item Response Theory (IRT) dan Bayesian IRT (IRT*)**: Pendekatan psikometri standar yang memodelkan probabilitas jawaban benar berdasarkan parameter siswa (θ) dan butir soal (b) (Handayani dkk. 2025). **Analisis terhadap Over-personalization**: Model IRT cenderung statis dan mengasumsikan parameter invarian. Sangat sulit untuk menyuntikkan "bobot sosial" ke dalam rumus IRT secara dinamis untuk mengubah rekomendasi soal secara *real-time* saat terdeteksi adanya isolasi pembelajaran (Vesin dkk. 2022).
- **Factor Analysis (FA)**: Teknik statistik yang digunakan untuk mengidentifikasi struktur faktor laten (seperti pengetahuan awal atau kemampuan kognitif) yang mendasari kinerja siswa (Ihichr dkk. 2024). **Analisis terhadap Over-personalization**: FA lebih cocok digunakan untuk validasi struktur tes atau analisis *post-hoc* (setelah data terkumpul) daripada pelacakan dinamis. Teknik ini tidak dirancang untuk pembaruan parameter *real-time* yang diperlukan untuk merespons perubahan perilaku sosial siswa seketika.
- **Bayesian Knowledge Tracing (BKT)**: Model berbasis *Hidden Markov Models* (HMM) yang melacak transisi biner status pengetahuan dari "belum belajar" ke "sudah belajar" (Minn 2022). **Analisis terhadap Over-personalization**: BKT memiliki struktur probabilitas yang kaku (mengandalkan parameter *guess* dan *slip*). Memasukkan variabel sosial kontinu ke dalam probabilitas transisi BKT sangat kompleks dan berisiko melanggar asumsi dasar model bahwa keterampilan tidak akan "dilupakan" (Ihichr dkk. 2024), padahal isolasi sosial mungkin memerlukan penurunan skor untuk memicu intervensi.
- **Deep Knowledge Tracing (DKT)**: Menggunakan jaringan saraf tiruan (*Re-*

current Neural Networks) untuk melacak pengetahuan (Minn 2022). **Analisis terhadap Over-personalization:** Meskipun akurasi tinggi, sifatnya yang *black-box* membuat sistem sulit mendeteksi *kenapa* seorang siswa terjebak dalam pola soal tertentu. Intervensi algoritmik untuk memecahkan *bubble* sulit dilakukan secara terukur karena kompleksitas parameternya.

- **Sistem Elo-rating:** Memodelkan interaksi siswa-konten sebagai kompetisi dengan rumus pembaruan sederhana: $R_{baru} = R_{lama} + K(S - E)$ (Vesin dkk. 2022). **Analisis terhadap Over-personalization:** Ini adalah kandidat terkuat karena keberadaan faktor K (koefisien bobot). Faktor ini dapat dimodifikasi secara eksplisit menjadi fungsi dari aktivitas sosial (misalnya, siswa yang kurang bersosialisasi mendapat K yang memaksa perubahan peringkat lebih cepat), memungkinkan integrasi langsung untuk melawan stagnasi algoritma.

III.3.1.2 Alternatif Teknik Interaksi dan Asesmen Sosial (R2 & R3)

Komponen ini bertujuan memfasilitasi interaksi yang bermakna. Untuk memecahkan *filter bubble*, aktivitas sosial harus memaksa siswa terpapar pada perspektif atau materi di luar preferensi historis mereka.

- **Pembelajaran Berbasis Proyek (*Project-Based Learning* / PBL):** Model pembelajaran yang di dalamnya siswa berkolaborasi untuk menghasilkan artefak proyek nyata (Zhang dan Ma 2023). **Analisis terhadap Over-personalization:** Sangat baik untuk kolaborasi mendalam, namun memiliki kendala besar dalam penilaian otomatis. Sulit bagi sistem untuk memisahkan kontribusi individu dari hasil kelompok (*free-rider problem*) secara akurat tanpa intervensi manual dosen (Ryoo dan Winkelmann 2021), sehingga sulit dijadikan input data *real-time* untuk algoritma adaptif.
- **Pendampingan Sejawat (*Peer Mentoring*):** Mekanisme bimbingan *one-on-one* antara siswa senior dan junior (Le, Sok, dan Heng 2024). **Analisis terhadap Over-personalization:** Hubungan ini seringkali bersifat hierarkis dan searah (senior mengajar junior), bukan kolaborasi setara. Hal ini kurang efektif untuk tujuan memecahkan *echo chamber* yang membutuhkan paparan terhadap berbagai perspektif sejawat yang beragam, bukan sekadar transfer pengetahuan vertikal.
- **Formasi Kelompok Berbasis Klustering (*Group Formation*):** Menggunakan algoritma seperti K-Means untuk membentuk kelompok heterogen di awal pembelajaran (Nalli, Amendola, dan Smith 2022). **Analisis terhadap Over-personalization:** Efektif untuk "memaksa" keberagaman di awal (*cold start*). Namun, karena sifatnya statis, teknik ini tidak menghasilkan data kinerja kon-

tinu yang bisa digunakan sistem untuk memantau apakah siswa kembali mengisolasi diri setelah kelompok terbentuk.

- **Sesi Diskusi Terbuka (*Open Discussion*):** Memfasilitasi forum bebas untuk pertukaran ide (Daif-Allah dan Khan 2016). **Analisis terhadap *Over-personalization*:** Dalam forum bebas, siswa cenderung mencari teman yang sepemikiran (*homophily*), yang justru memperkuat *echo chamber* alih-alih memecahkannya. Selain itu, sulit menilai kualitas interaksi secara otomatis tanpa NLP yang kompleks.
- **Penilaian Sejawat (*Peer Assessment*):** Siswa menilai pekerjaan rekan lain berdasarkan rubrik dengan status yang setara (Ihichr dkk. 2024). **Analisis terhadap *Over-personalization*:** Teknik ini paling potensial karena sistem memegang kendali penuh atas "siapa menilai siapa". Sistem dapat menugaskan siswa untuk menilai rekan yang memiliki sudut pandang bertentangan atau tingkat kemampuan berbeda (di luar *bubble*-nya). Selain itu, kualitas umpan balik (R3) dapat diukur sebagai metrik keterbukaan siswa terhadap kolaborasi (Lu dan Zhang 2012).

III.3.1.3 Alternatif Teknik Pencegahan *Echo Chamber* dan *Filter Bubble*

Subbab ini mengevaluasi pendekatan spesifik yang telah dikembangkan dalam literatur sistem rekomendasi untuk mengatasi masalah isolasi, guna melihat kesesuaiannya untuk diadopsi ke dalam sistem asesmen pendidikan.

- ***User-Controllable Recommender Systems (UCRS)*:** Pendekatan yang memberikan fitur kendali eksplisit kepada pengguna untuk mengatur tingkat diversifikasi rekomendasi mereka sendiri (Wang dkk. 2022). **Analisis:** Pendekatan ini sangat bergantung pada kesadaran pengguna. Dalam konteks pendidikan, siswa seringkali tidak menyadari bahwa mereka berada dalam *bubble* kompetensi ("*unconscious incompetence*"). Mengandalkan siswa untuk secara manual meminta materi yang "tidak mereka sukai" berisiko tidak efektif dibandingkan intervensi otomatis.
- ***Group Recommender Systems (GRS)*:** Teknik yang merekomendasikan konten berdasarkan preferensi agregat dari sekelompok pengguna untuk meningkatkan keadilan (*fairness*) dan pluralitas (Dokoupil 2022). **Analisis:** GRS cenderung memprioritaskan konsensus kelompok atau rata-rata preferensi. Dalam pembelajaran adaptif, hal ini berisiko mengorbankan personalisasi spesifik yang dibutuhkan siswa *outlier* (sangat mahir atau sangat tertinggal), karena rekomendasi akan tertarik ke arah "pusat" kelompok, yang bisa menyebabkan *under-personalization*.

- **Pemodelan Komunitas Implisit (*FRediECH*):** Sebuah teknik rekomendasi teman yang dirancang khusus untuk memecahkan *echo chamber* dengan merekomendasikan koneksi sosial yang beragam namun relevan, berdasarkan pembelajaran representasi interaksi pengguna menggunakan *Graph Neural Networks* (Tommasel, Rodriguez, dan Godoy 2021). **Analisis:** Teknik ini sangat kuat untuk memecah polarisasi opini. Namun, kelemahan utamanya adalah kebutuhan akan data pelatihan yang besar untuk membangun graf interaksi awal (*cold-start problem*), sehingga sulit diterapkan pada fase awal implementasi sistem tanpa dataset historis.
- **Constraint-based Re-ranking:** Metode pasca-pemrosesan (*post-processing*) yang menyusun ulang daftar rekomendasi awal agar memenuhi batasan (*constraints*) distribusi tertentu, misalnya menetapkan persentase minimum item yang bersifat "favorable" atau beragam (Biasio dkk. 2023). **Analisis:** Pendekatan ini bersifat agnostik terhadap model dasar dan bekerja berdasarkan aturan logis (α dan β) pada daftar rekomendasi yang ada. Keunggulan utamanya adalah efisiensi komputasi dan kemampuan untuk langsung berfungsi tanpa memerlukan pelatihan model data yang ekstensif (*training-free*), menjadikannya solusi yang sangat potensial untuk kondisi data terbatas.

III.3.2 Analisis Penentuan Solusi

Penentuan solusi teknis dilakukan menggunakan metode *Weighted Decision Matrix* (Matriks Keputusan Terbobot). Pendekatan ini digunakan untuk memilih komponen sistem secara objektif berdasarkan kriteria yang diturunkan dari Batasan Masalah (Bab I) dan Tinjauan Literatur (Bab II).

Analisis dibagi menjadi tiga keputusan terpisah untuk memilih: (1) Teknik Asesmen Individu, (2) Teknik Interaksi Sosial, dan (3) Teknik Mitigasi *Over-personalization*.

III.3.2.1 Keputusan 1: Penentuan Teknik Asesmen Individu

Tujuannya adalah memilih algoritma pelacakan pengetahuan. Berdasarkan tinjauan literatur, kandidat utamanya adalah IRT, FA, BKT, DKT, dan Elo-rating.

Tabel III.4 Matriks Keputusan: Teknik Asesmen Individu

Kriteria	Bobot	IRT	FA	BKT	DKT	Elo
Efisiensi Komputasi	30%	2	1	3	1	5
Kebutuhan Data Awal (Cold Start)	30%	2	2	3	2	5
Akurasi Pelacakan	20%	4	3	3	5	4
Interpretabilitas	20%	4	3	4	1	5
Skor Terbobot	100%	2.8	2.1	3.2	2.1	4.8

Rasionalisasi Objektif dan Analisis *Trade-off*:

- **Efisiensi & Kebutuhan Data (Bobot Tinggi - 60%):** Kriteria ini diberi bobot tertinggi mengingat batasan masalah pengembangan purwarupa yang mungkin tidak memiliki dataset historis besar. **Elo-rating** unggul mutlak (skor 5) karena algoritma ini dirancang untuk bekerja tanpa pra-kalibrasi yang rumit dan efisien secara komputasi (Vesin dkk. 2022). Sebaliknya, **IRT** dan **FA** membutuhkan sampel besar untuk kalibrasi parameter butir soal, dan **DKT** membutuhkan data pelatihan masif untuk melatih jaringan saraf (Minn 2022).
- **Akurasi vs. Kelayakan (Trade-off):** **DKT** memiliki skor akurasi tertinggi (5) karena kemampuannya menangkap pola kompleks (Minn 2022). Namun, terjadi *trade-off* signifikan pada aspek **Interpretabilitas** (skor 1) karena sifat *black-box*-nya, yang menyulitkan sistem untuk menjelaskan alasan rekomendasi kepada siswa. **Elo-rating** dipilih bukan karena ia paling akurat, tetapi karena ia adalah solusi paling layak (*feasible*) untuk diimplementasikan dalam skenario data terbatas dengan akurasi yang masih dapat diterima.

III.3.2.2 Keputusan 2: Penentuan Teknik Interaksi Sosial

Tujuannya adalah memilih bentuk aktivitas sosial yang dapat memfasilitasi kolaborasi sekaligus menghasilkan data yang dapat diolah sistem.

Tabel III.5 Matriks Keputusan: Teknik Interaksi Sosial

Kriteria	Bobot	PBL	Mentor	Group	Diskusi	Peer Assmt.
Keterukuran Data (Measurability)	35%	2	3	1	1	5
Kesetaraan Interaksi	25%	5	2	5	5	5
Potensi Eksposur Keberagaman	25%	4	2	3	3	5
Kompleksitas Implementasi	15%	2	3	4	3	4
Skor Terbobot	100%	3.25	2.5	3.0	2.8	4.85

Rasionalisasi Objektif dan Analisis *Trade-off*:

- **Keterukuran Data (35%):** Sistem membutuhkan input kuantitatif untuk algoritma (FR-06). **Peer Assessment** mendapatkan skor tertinggi (5) karena menghasilkan artefak terstruktur (skor rubrik dan teks umpan balik) yang mudah dikuantifikasi (Ihichr dkk. 2024). Sebaliknya, **Diskusi Terbuka** dan **PBL** (Project-Based Learning) sangat sulit dinilai kontribusi individunya secara otomatis tanpa intervensi manual dosen (Ryoo dan Winkelmann 2021).
- **Kesetaraan & Eksposur (Trade-off):** **Mentoring** mendapat skor rendah pada kesetaraan (2) karena sifatnya hierarkis (senior-junior) (Le, Sok, dan Heng 2024), yang kurang cocok untuk memecah *echo chamber* dibandingkan interaksi setara. **PBL** sebenarnya sangat baik dalam kesetaraan dan kolaborasi mendalam (skor 5), namun dipilihnya **Peer Assessment** merupakan *trade-off* logis karena PBL memiliki kompleksitas implementasi yang tinggi dan risiko *free-rider* yang sulit dideteksi sistem (Zhang dan Ma 2023). **Peer Assessment** dipilih karena memungkinkan sistem "mengatur" siapa menilai siapa untuk memaksa eksposur keberagaman.

III.3.2.3 Keputusan 3: Penentuan Teknik Mitigasi *Over-personalization*

Keputusan ini bertujuan memilih mekanisme teknis untuk memecahkan *echo chamber* yang dapat beroperasi secara otomatis dan layak diimplementasikan segera tanpa data pelatihan (*cold-start*).

Tabel III.6 Matriks Keputusan: Teknik Mitigasi Isolasi

Kriteria	Bobot	Alt A (UCRS)	Alt B (GRS)	Alt C (FRediECH)	Alt D (Re-rank)
Otomasi Intervensi	35%	1	4	5	5
Kelayakan Cold-Start	35%	5	4	1	5
Preservasi Personalisasi	30%	5	2	4	4
Skor Terbobot	100%	3.6	3.4	3.3	4.7

Rasionalisasi Objektif dan Analisis *Trade-off*:

- **Otomasi Intervensi (35%):** Alt A (UCRS) mendapat skor terendah (1) karena bergantung pada inisiatif pengguna yang seringkali bias atau pasif. Alt C (FRediECH) dan Alt D (Re-ranking) unggul (5) karena sistem secara proaktif melakukan intervensi untuk memecah *bubble* tanpa menunggu tindakan pengguna.
- **Kelayakan Cold-Start (35%):** Kriteria ini krusial untuk purwarupa. Alt C (FRediECH) mendapat penalti besar (1) karena berbasis *Deep Learning* yang membutuhkan data historis masif untuk pelatihan awal. Sebaliknya, Alt D (Re-ranking) mendapat skor sempurna (5) karena algoritma ini bekerja secara *greedy* pada daftar yang ada berdasarkan aturan logis, sehingga bisa langsung berjalan sejak hari pertama implementasi (Biasio dkk. 2023).
- **Preservasi Personalisasi (30%):** Alt B (GRS) cenderung menarik rekomendasi ke rata-rata kelompok, mengorbankan preferensi unik individu (skor 2). Alt D (Re-ranking) dinilai baik (4) karena hanya memodifikasi sebagian kecil daftar rekomendasi (sesuai parameter α) untuk menyuntikkan keberagaman, sementara sisa daftar tetap mempertahankan personalisasi berbasis kompetensi individu.
- **Kesimpulan: Constraint-based Re-ranking** (Biasio dkk. 2023) dipilih. Metode ini menawarkan keseimbangan terbaik: ia seotomatis FRediECH dalam memecahkan isolasi, namun sefleksibel UCRS dalam hal implementasi tanpa data (*cold-start*). Sistem akan menggunakan algoritma ini untuk memfilter calon mitra *peer assessment*, memastikan setiap siswa terpapar pada rekan dengan tingkat kemahiran yang beragam (heterogen) sesuai batasan statistik yang ditentukan.

III.3.3 Keputusan Akhir Pemilihan Solusi

Berdasarkan analisis komparatif yang telah dilakukan melalui matriks keputusan, penelitian ini menetapkan arsitektur solusi yang terdiri dari tiga komponen utama yang saling terintegrasi. Pemilihan ini didasarkan pada prinsip efisiensi komputasi, ketersediaan data pada fase awal (*cold-start*), dan validitas pedagogis untuk mitigasi risiko *over-personalization*.

Komponen pertama yang menjadi fondasi pelacakan kompetensi adalah **Sistem Elo-rating**. Berbeda dengan model probabilitas statis seperti IRT atau model berbasis *Deep Learning* seperti DKT yang membutuhkan dataset historis masif, Elo-rating dipilih karena kemampuannya untuk beradaptasi secara dinamis dengan ukuran sampel yang kecil (*small sample size*). Algoritma ini akan berfungsi sebagai mesin utama untuk mengestimasi parameter kemahiran siswa secara *real-time* setelah setiap interaksi, memberikan landasan data yang akurat namun ringan secara komputasi untuk proses adaptasi selanjutnya (Vesin dkk. 2022).

Sebagai mekanisme interaksi sosial, sistem akan mengimplementasikan **Peer Assessment** (penilaian sejawat). Keputusan ini diambil karena aktivitas ini menawarkan keuntungan ganda: secara teknis, ia menghasilkan artefak data kuantitatif (skor penilaian) yang terstruktur dan mudah diolah oleh algoritma; secara pedagogis, ia memberikan manfaat metakognitif tertinggi bagi siswa yang berperan sebagai penilai (*assessor*) (Lu dan Zhang 2012). Aktivitas ini menjadi wadah strategis bagi sistem untuk menyuntikkan intervensi sosial yang terukur, menggantikan interaksi diskusi bebas yang sulit dikuantifikasi.

Komponen krusial yang mengikat kedua elemen di atas untuk memecahkan isolasi pembelajaran adalah algoritma **Constraint-based Re-ranking**. Diadaptasi dari kerangka kerja Biasio dkk. (2023), teknik ini dipilih sebagai strategi mitigasi utama karena keunggulannya dalam menangani masalah *cold-start* dibandingkan pendekatan berbasis graf seperti FRediECH. Sistem akan menggunakan algoritma ini untuk memfilter daftar calon mitra *peer assessment* dengan menerapkan batasan (*constraint*) statistik α . Batasan ini memastikan bahwa setiap siswa terpapar pada proporsi minimum rekan yang memiliki tingkat kemahiran berbeda (heterogen), yang dihitung berdasarkan jarak skor Elo mereka. Dengan demikian, sistem menjamin terjadinya diversifikasi perspektif dan pemecahan *echo chamber* kompetensi secara otomatis sejak hari pertama operasional.

DAFTAR PUSTAKA

- Biasio, Alvise De, Merylin Monaro, Luca Oneto, Lamberto Ballan, dan Nicolò Navarin. 2023. “On the problem of recommendation for sensitive users and influential items: Simultaneously maintaining interest and diversity”. *Knowledge-Based Systems* 275. ISSN: 09507051. <https://doi.org/10.1016/j.knosys.2023.110699>.
- Brusilovsky, Peter, Sibel Somyurek, Julio Guerra, Roya Hosseini, Vladimir Zadorozhny, dan Paula J. Durlach. 2016. “Open Social Student Modeling for Personalized Learning”. *IEEE Transactions on Emerging Topics in Computing* 4 (3): 450–461. ISSN: 21686750. <https://doi.org/10.1109/TETC.2015.2501243>.
- Cohen, Jacob. 1988. *Statistical Power Analysis for the Behavioral Sciences Second Edition*. 2nd. Lawrence Erlbaum Associates. ISBN: 0-8058-0283-5.
- Coletta, Vincent P., dan Jeffrey J. Steinert. 2020. “Why normalized gain should continue to be used in analyzing preinstruction and postinstruction scores on concept inventories”. *Physical Review Physics Education Research* 16 (1). ISSN: 24699896. <https://doi.org/10.1103/PhysRevPhysEducRes.16.010108>.
- Computing Education in Community Colleges, ACM Committee for. 2023. *Bloom’s for Computing: Enhancing Bloom’s Revised Taxonomy with Verbs for Computing Disciplines*. ACM. <https://doi.org/10.1145/3587276>.
- Daif-Allah, Ayman Sabry, dan Mohammad Imran Khan. 2016. “The Impact of Open Discussion Sessions on Enhancing the Oral Communicative Abilities of Saudi English Language Majors at Buraydah Community College”. *English Language Teaching* 9 (6): 108. ISSN: 1916-4742. <https://doi.org/10.5539/elt.v9n6p108>.
- Dokoupil, Patrik. 2022. “Long-term fairness for Group Recommender Systems with Large Groups”, 724–726. Association for Computing Machinery, Inc. ISBN: 9781450392785. <https://doi.org/10.1145/3523227.3547424>.

- Elo, Arpad E. 1978. *THE RATING OF CHESSPLAYERS PAST & PRESENT*. 2nd. Arco Publishing Inc. ISBN: 0-668-04721-6.
- Fu, Xinjian, dan Qinbing Li. 2025. "Effectiveness of Role-play Method: A Meta-analysis". *International Journal of Instruction* 18 (1): 309–324. ISSN: 1694609X. <https://doi.org/10.29333/iji.2025.18117a>. http://www.e-iji.net/dosyalar/iji_2025_1_17.pdf.
- Gosselin, Kathryn, dan Nicole Okamoto. 2018. "Improving Instruction and Assessment via Bloom's Taxonomy and Descriptive Rubrics". Dalam *2018 ASEE Annual Conference & Exposition Proceedings*. ASEE Conferences. <https://doi.org/10.18260/1-2--30630>. <http://peer.asee.org/30630>.
- Halkiopoulos, Constantinos, dan Evgenia Gkintoni. 2024. "Leveraging AI in E-Learning: Personalized Learning and Adaptive Assessment through Cognitive Neuropsychology—A Systematic Analysis". *Electronics (Switzerland)* 13 (18). ISSN: 20799292. <https://doi.org/10.3390/electronics13183762>.
- Handayani, Dian, Muhammad Alief Ghifari, Vera Maya Santi, dan Rahfa Qur'aniyatin Dhuha. 2025. "ITEM RESPONSE MODEL FOR ANALYZING ITEM RESPONSES IN THE INSTRUMENT OF CHANGE MANAGEMENT AND ORGANIZATIONAL CULTURE". *Jurnal Statistika dan Aplikasinya* 9 (1): 37–49. <https://doi.org/10.21009/jsa.09104>.
- Ihichr, Adel, Omar Oustous, Younes El Bouzekri, El Idrissi, dan Ayoub Ait Lahcen. 2024. *A Systematic Review on Assessment in Adaptive Learning: Theories, Algorithms and Techniques*. www.ijacsa.thesai.org.
- Kelompok Kerja Penyusun Strategi Nasional untuk Kecerdasan Artifisial. 2020. *AI TOWARDS INDONESIA VISION 2045*. Badan Pengkajian dan Penerapan Teknologi.
- Le, Huong-Giang, Sarin Sok, dan Kimkong Heng. 2024. *Journal of Learning Development in Higher Education The benefits of peer mentoring in higher education: findings from a systematic review*.
- Lu, Jingyan, dan Zhidong Zhang. 2012. "Understanding the Effectiveness of Online Peer Assessment: A Path Model". *Journal of Educational Computing Research* 46 (3): 313–333. ISSN: 0735-6331. <https://doi.org/10.2190/EC.46.3.f>. <https://journals.sagepub.com/doi/10.2190/EC.46.3.f>.

- Minn, Sein. 2022. "AI-assisted knowledge assessment techniques for adaptive learning environments". *Computers and Education: Artificial Intelligence* 3. ISSN: 2666920X. <https://doi.org/10.1016/j.caeai.2022.100050>.
- Nalli, Giacomo, Daniela Amendola, dan Serengul Smith. 2022. "Artificial Intelligence to improve learning outcomes through online collaborative activities". *European Conference on e-Learning* 21 (1): 475–479. ISSN: 2048-8645. <https://doi.org/10.34190/ecel.21.1.661>. <https://papers.academic-conferences.org/index.php/ecel/article/view/661>.
- Nissen, Jayson M., Robert M. Talbot, Amreen Nasim Thompson, dan Ben Van Dusen. 2018. "Comparison of normalized gain and Cohen's d for analyzing gains on concept inventories". *Physical Review Physics Education Research* 14 (1). ISSN: 24699896. <https://doi.org/10.1103/PhysRevPhysEducRes.14.010115>.
- Ryoo, Jungwoo, dan Kurt Winkelmann. 2021. *Innovative Learning Environments in STEM Higher Education*. <http://www.springer.com/series/8921>.
- Tommasel, Antonela, Juan Manuel Rodriguez, dan Daniela Godoy. 2021. "I Want to break free! recommending friends from outside the echo chamber", 23–33. Association for Computing Machinery, Inc. ISBN: 9781450384582. <https://doi.org/10.1145/3460231.3474270>.
- Vesin, Boban, Katerina Mangaroska, Kamil Akhuseyinoglu, dan Michail Giannakos. 2022. "Adaptive Assessment and Content Recommendation in Online Programming Courses: On the Use of Elo-rating". *ACM Transactions on Computing Education* 22 (3). ISSN: 19466226. <https://doi.org/10.1145/3511886>.
- Wang, Wenjie, Fuli Feng, Liqiang Nie, dan Tat Seng Chua. 2022. "User-controllable Recommendation Against Filter Bubbles", 1251–1261. Association for Computing Machinery, Inc. ISBN: 9781450387323. <https://doi.org/10.1145/3477495.3532075>.
- Wu, Yong, dan Christian D. Schunn. 2020. "From feedback to revisions: Effects of feedback features and perceptions". *Contemporary Educational Psychology* 60. ISSN: 10902384. <https://doi.org/10.1016/j.cedpsych.2019.101826>.
- Zhang, Lu, dan Yan Ma. 2023. "A study of the impact of project-based learning on student learning effects: a meta-analysis study". *Frontiers in Psychology* 14. ISSN: 16641078. <https://doi.org/10.3389/fpsyg.2023.1202728>.